بسم الله الرحمن الرحیم

دانشگاه صنعتی شریف
دانشکده‌ی مهندسی کامپیوتر

یادگیری عمیق

نیم‌سال دوم ۰۵-۰۴

مدرس: مهدیه سلیمانی

تمرین چهارم | ددلاین تمرین : ۹ تیر

- برای ارسال هر تمرین تا ساعت ۲۳:۵۹ روز ددلاین فرصت دارید. مهلت تاخیر (مجاز و غیر مجاز) برای این تمرین ۷ روز است (یعنی حداکثر تاریخ ارسال تمرین ۱۶ تیر است)
- در هر کدام از سوالات، اگر از منابع خارجی استفاده کرده‌اید باید آن را ذکر کنید. در صورت همفکری با افراد دیگر هم باید نام ایشان را در سوال مورد نظر ذکر نمایید.
- پاسخ تمرین باید ماحصل دانسته‌های خود شما باشد. در صورت رعایت این موضوع، استفاده از ابزارهای هوش مصنوعی با ذکر نحوه و مصداق استفاده بلامانع است.
- پاسخ ارسالی واضح و خوانا باشد. در غیر این صورت ممکن است منجر به از دست دادن نمره شود.
- از تحویل تمارین نظری به شکل تایپ شده (فایل Word-Latex یا هر نوع تایپ شده دیگری) بپرهیزید و حتما پاسخ دست نویس تحویل دهید.
- پاسخ ارسالی باید توسط خود شما نوشته شده باشد. به اسکرین‌شات از منابع یا پاسخ افراد دیگر نمره‌ای تعلق نمی‌گیرد.
- در صورتی که بخشی از سوال‌ها را جای دیگری آپلود کرده و لینک آن را قرار داده باشید، حتما باید تاریخ آپلود مشخص و قابل اتکا باشد.
- محل بارگذاری سوالات نظری و عملی در هر تمرین مجزا خواهد بود. به منظور بارگذاری بایستی تمارین تئوری در یک فایل pdf با نام HW4_[First-Name]_[Last-Name]_[Student-Id].pdf بارگذاری شوند.
- در صورت وجود هرگونه ابهام یا مشکل، در کوئرای درس آن مشکل را بیان کنید و از پیغام دادن مستقیم به دستیاران آموزشی خودداری کنید.
- طراحان این تمرین : رضا قربانی، مبینا پولائی، مزدک تیموریان، مهشید دهقانی، حسین شریفی، مریم ولی، امیرحسین ایزدی

بخش نظری (۱۰۰ نمره)

پرسش ۱. Hierarchical VAEs (۲۰ نمره)

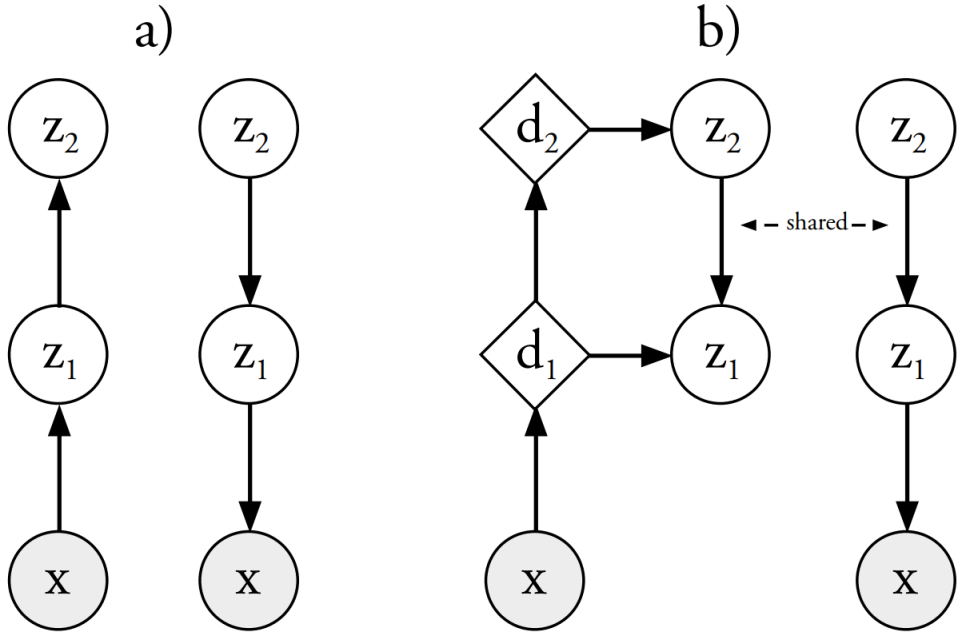
Ladder Variational Autoencoders (LVAE) متعلق به خانواده Hierarchical VAEs هستند، یعنی مدل‌های مولد که در آن‌ها پشته‌ای از متغیرهای نهان تصادفی (stochastic latent variables) به صورت $z = (z_1, z_2, \ldots, z_L)$ در یک Markov chain از سطح بالا چیده شده‌اند. توزیع توأم به صورت زیر بیان می‌شود:

$$p_\theta(x, z) = p_\theta(x \mid z_1)\, p_\theta(z_L) \prod_{i=1}^{L-1} p_\theta(z_i \mid z_{i+1}).$$

در یک VAE استاندارد، مدل استنتاج (encoder) کاملاً پایین‌به‌بالا (bottom-up) است: با شروع از داده x، یک شبکهٔ deterministic پارامترهای هر $q_\phi(z_i \mid z_{i-1})$ را تولید می‌کند. اما LVAE به جای آن از استنتاج بالا-به-پایین (top-down inference) استفاده می‌کند که اطلاعات را از دو منبع ادغام می‌نماید:

- یک approximate likelihood پایین‌ـبه‌ـبالا $(\hat{\mu}_{q,i}, \hat{\sigma}^2_{q,i})$ که توسط یک گذر deterministic به سمت بالا به دست می‌آید.
- prior بالاـبه‌ـپایین $(\mu_{p,i}, \sigma^2_{p,i})$ که از ساختار سلسله‌مراتبی مدل مولد (generative model) می‌آید.

این تلفیق با یک ترکیب precision-weighted انجام می‌شود، دقیقاً همان‌طور که یک likelihood گاوسی و یک prior گاوسی را ترکیب می‌کنیم. شکل ۱ جریان اطلاعات را در یک VAE استاندارد و در LVAE مقایسه می‌کند.



شکل ۱: ساختار VAE (a) و LVAE (b)

در شکل ۱، دایره‌ها متغیرهای stochastic، لوزی‌ها متغیرهای deterministic هستند. در VAE استنتاج کاملاً bottom-up است؛ در LVAE استنتاج از همان وابستگی top-down مشابه مدل مولد استفاده می‌کند و به prior مولد اجازه می‌دهد تا به صورت بازگشتی توسط یک approximate likelihood وابسته به داده تصحیح شود.

(الف)

کران پایینی شواهد (evidence lower bound - ELBO) را برای مدل متغیر نهان سلسله‌مراتبی (hierarchical latent variable model) که در بالا توضیح داده شد، بنویسید. فرض کنید که posterior تقریبی factorised شده به صورت

$$q_\phi(z \mid x) = \prod_{i=1}^{L} q_\phi(z_i \mid z_{i+1}, x)$$

است (که در آن $z_{L+1} \equiv \emptyset$ تعریف می‌شود). جملهٔ بازسازی (reconstruction term) و عبارت‌های منظم‌سازی (regularisation) مبتنی بر KL-divergence را مشخص کنید. چگونه عبارت منظم‌سازی، تعیین خودکار ارتباط (automatic relevance determination) واحدهای نهان را اعمال می‌کند؟

(ب)

در LVAE، posterior تقریبی لایه i به صورت یک Gaussian با میانگین $\mu_{q,i}$ و واریانس $\sigma^2_{q,i}$ ساخته می‌شود که به شکل زیر داده می‌شود:

$$\sigma_{q,i} = \frac{1}{\hat{\sigma}_{q,i}^{-2} + \sigma_{p,i}^{-2}}, \quad \mu_{q,i} = \frac{\hat{\mu}_{q,i}\,\hat{\sigma}_{q,i}^{-2} + \mu_{p,i}\,\sigma_{p,i}^{-2}}{\hat{\sigma}_{q,i}^{-2} + \sigma_{p,i}^{-2}}. \quad (19)$$

این فرمول‌ها را با ترکیب صریح یک Gaussian likelihood $\mathcal{N}(z_i \mid \hat{\mu}_{q,i}, \hat{\sigma}_{q,i}^2)$ با یک Gaussian prior $\mathcal{N}(z_i \mid \mu_{p,i}, \sigma_{p,i}^2)$ از طریق قواعد Bayes استخراج کنید.
چرا می‌توان $\hat{\mu}_{q,i}, \hat{\sigma}_{q,i}^2$ را به عنوان پارامترهای یک approximate Gaussian likelihood تفسیر کرد؟

(ج)

مدل استنتاج LVAE مجدداً از همان ساختار top down مشابه مدل مولد استفاده می‌کند. توضیح دهید که چگونه پارامترهای استنتاج (به طور خاص $\mu_{p,i}, \sigma_{p,i}$) از مسیر مولد (generative path) به دست می‌آیند و چرا این اشتراک پارامتر صریح، مسئله بهینه‌سازی را نسبت به یک inference network purely bottom up که هیچ دانشی از توزیع مولد (generative distribution) ندارد، آسان‌تر می‌کند.

(د)

هدف آموزش (training objective) که در طول warm-up استفاده می‌شود به صورت زیر است:

$$\mathcal{L}_T(\theta, \phi; x) = -\beta\, KL(q_\phi(z \mid x) \| p_\theta(z)) + \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x \mid z)], \quad (20)$$

که در آن β به طور خطی از ۰ به ۱ طی N_t دوره (epoch) افزایش می‌یابد.

(i) نشان دهید که برای $\beta = 0$ مدل به یک خودرمزگذار قطعی (deterministic autoencoder) استاندارد تبدیل می‌شود.

(ii) توضیح دهید چرا شروع با $\beta = 0$ از collapse واحدهای نهان (latent units) در مراحل اولیه آموزش جلوگیری می‌کند.

(iii) اگر β از ابتدا برابر ۱ قرار داده شود چه اتفاقی می‌افتد؟

پاسخ. ◁

(الف)

Generative model دارای L لایه از stochastic latent variables $z = (z_1, \ldots, z_L)$ است. Joint distribution به صورت زیر تعریف می‌شود:

$$p_\theta(x, z) = p_\theta(x \mid z_1)\, p_\theta(z_L) \prod_{i=1}^{L-1} p_\theta(z_i \mid z_{i+1}),$$

یعنی یک top-down Markov chain که در آن z_L بالاترین latent و z_1 نزدیک‌ترین به داده است.
Inference model (تقریب پسین approximate posterior) نیز به صورت بالا به پایین فاکتوریزه می‌شود:

$$q_\phi(z \mid x) = q_\phi(z_L \mid x) \prod_{i=1}^{L-1} q_\phi(z_i \mid z_{i+1}, x),$$

با قرارداد $z_{L+1} \equiv \emptyset$. توجه کنید که همان ساختار وابستگی در هر دو generative and inference models ظاهر می‌شود – این ایده اصلی Ladder VAE است.

لگاریتم درستنمایی حاشیه‌ای marginal log-likelihood $\log p_\theta(x)$ از پایین با standard variational lower bound محدود می‌شود:

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_\phi(z|x)}\big[\log p_\theta(x \mid z)\big] - \mathrm{KL}\big(q_\phi(z \mid x) \parallel p_\theta(z)\big).$$

با استفاده از فاکتوریزه‌های بالا، عبارت KL را می‌توان به صورت بازگشتی تجزیه کرد. Prior به صورت $p_\theta(z) = p_\theta(z_L)\prod_{i=1}^{L-1} p_\theta(z_i \mid z_{i+1})$ و approximate posterior به صورت $q_\phi(z \mid x) = q_\phi(z_L \mid x)\prod_{i=1}^{L-1} q_\phi(z_i \mid z_{i+1}, x)$ فاکتوریزه می‌شود. اعمال قانون زنجیره‌ای برای واگرایی‌های KL (یا مستقیماً نوشتن نسبت لگاریتمی) نتیجه می‌دهد:

$$\begin{aligned}&\mathrm{KL}\big(q_\phi(z \mid x) \parallel p_\theta(z)\big) = \\ &\qquad \mathrm{KL}\big(q_\phi(z_L \mid x) \parallel p_\theta(z_L)\big) + \sum_{i=1}^{L-1} \mathbb{E}_{q_\phi(z_{i+1}|x)}\Big[\mathrm{KL}\big(q_\phi(z_i \mid z_{i+1}, x) \parallel p_\theta(z_i \mid z_{i+1})\big)\Big].\end{aligned}$$

از آنجا که بازسازی reconstruction فقط به z_1 وابسته است، داریم $\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x \mid z)] = \mathbb{E}_{q_\phi(z_1|x)}[\log p_\theta(x \mid z_1)]$، اما در اینجا ساده‌تر است که آن را در امیدواری مشروط به z کامل نگه داریم و توجه کنیم که generative model فقط از z_1 استفاده می‌کند.
بنابراین ELBO کامل برای یک hierarchical VAE با L لایه دقیقاً به صورت زیر است:

$$\begin{aligned}\mathcal{L}(\theta, \phi; x) =& \mathbb{E}_{q_\phi(z|x)}\big[\log p_\theta(x \mid z_1)\big] \\ &- \mathrm{KL}\big(q_\phi(z_L \mid x) \parallel p_\theta(z_L)\big) \\ &- \sum_{i=1}^{L-1} \mathbb{E}_{q_\phi(z_{i+1}|x)}\Big[\mathrm{KL}\big(q_\phi(z_i \mid z_{i+1}, x) \parallel p_\theta(z_i \mid z_{i+1})\big)\Big].\end{aligned}$$

در این عبارت:

- Reconstruction term – اولین $\mathbb{E}_q[\log p_\theta(x \mid z_1)]$ اندازه می‌گیرد که مدل چقدر خوب داده را از پایین‌ترین نمایش نهان lowest latent representation بازسازی می‌کند.
- Regularisation terms –مجموع KL divergences انحراف approximate posterior از top down prior را در هر لایه جریمه می‌کند.. بالاترین لایه دارای یک prior ساده $p_\theta(z_L)$ (معمولاً یک standard Gaussian) است، در حالی که لایه‌های پایین‌تر $i < L$ به سمت conditional prior $p_\theta(z_i \mid z_{i+1})$ منظم می‌شوند.

(ب)

یک prior گاوسی $p(z_i) = \mathcal{N}(\mu_p, \sigma_p^2)$ و یک likelihood گاوسی $\ell(z_i) \propto \mathcal{N}(\hat{\mu}_q, \hat{\sigma}_q^2)$ را در نظر بگیرید. posterior متناسب با حاصل‌ضرب زیر است:

$$q(z_i) \propto \exp\left(-\frac{(z-\hat{\mu}_q)^2}{2\hat{\sigma}_q^2}\right)\exp\left(-\frac{(z-\mu_p)^2}{2\sigma_p^2}\right).$$

با کامل کردن مربع، یک توزیع گاوسی با واریانس $\sigma_q^2 = (\hat{\sigma}_q^{-2} + \sigma_p^{-2})^{-1}$ و میانگین $\mu_q = \sigma_q^2(\hat{\mu}_q\hat{\sigma}_q^{-2} + \mu_p\sigma_p^{-2})$ به دست می‌آید.
پارامترهای پایین‌به‌بالا $\hat{\mu}_q, \hat{\sigma}_q^2$ توسط یک deterministic MLP به دست می‌آیند که data (یا lower hidden states) را به natural parameters یک توزیع گاوسی نگاشت می‌کند. این پارامترها را می‌توان به عنوان پارامترهای یک approximate Gaussian likelihood در نظر گرفت زیرا اگر به طور موقت data را به صورت conditionally Gaussian با شرط z_i در نظر بگیریم، خروجی MLP یک mean و variance ارائه می‌دهد که اطلاعات را خلاصه می‌کند.

(ج)

درLVAE، پارامترهای top-down parameters $\mu_{p,i}$ و $\sigma_{p,i}$ توسط همان تبدیل‌های قطعی محاسبه می‌شوند که prior generative model $p_\theta(z_i \mid z_{i+1})$ را تعریف می‌کنند. بنابراین inference network نیازی به یادگیری یک mapping کاملاً مستقل ندارد؛ تنها نیاز دارد که با استفاده از bottom-up approximate likelihood، prior را تصحیح کند. این sharing دو فایده دارد:

۱. gradients به صورت منسجم از هر دو مسیر جریان می‌یابند و mismatch بین q و p را کاهش می‌دهند.

۲. به جای fitting یک posterior کاملاً جدید، inference network تنها یک residual precision-weighted update را محاسبه می‌کند که یک optimisation problem ساده‌تر است.

(د)

(i) هنگامی که $\beta = 0$، عبارت KL حذف شده و تابع هدف به $\mathbb{E}_q[\log p(x|z)]$ تبدیل می‌شود. در این حالت q بهینه به یک point mass در رمز بیشینه‌درست‌نمایی تبدیل شده و عملاً encoder را به یک نگاشت قطعی تبدیل می‌کند. این معادل آموزش یک autoencoder استاندارد است.
(ii) در مراحل اولیه آموزش، encoder هنوز ویژگی‌های مفیدی یاد نگرفته و تنظیم KL تمام واحدهای پسین را به سمت پیشین هل می‌دهد و آنها را غیرفعال می‌کند ($KL \approx 0$) و در یک بهینه محلی گیر می‌اندازد. با نگه داشتن $\beta = 0$ در ابتدا، شبکه می‌تواند نخست یک نمایش قطعی خوب را تنها با استفاده از خطای بازسازی یاد بگیرد. وقتی β به تدریج افزایش می‌یابد، عبارت KL به آرامی وارد می‌شود و اجازه می‌دهد سیگنال‌های شیب واحدها را فعال نگه دارند.
(iii) با $\beta = 1$ از ابتدا، عبارت KL بر encoder آموزش‌ندیده چیره شده و باعث posterior collapse فوری بیشتر واحدهای نهفته می‌شود.

پرسش ۲. از GAN تا فروپاشی مد: واگرایی‌ها، پایداری، و معیارهای کیفیت (۲۰ نمره)

پیش‌زمینه: مدل‌های مولد تخاصمی (GAN) با معرفی گودفلو و همکاران (۲۰۱۴) انقلابی در یادگیری عمیق ایجاد کردند. اما به‌سرعت مشخص شد که GANهای استاندارد مبتنی بر واگرایی جنسن–شنون (JS) دچار یک نقص **ساختاری** هستند: **فروپاشی مد** (mode collapse) و **ناپدید شدن گرادیان**. در این پرسش، ریشه‌ی این مشکلات را در انتخاب واگرایی، سپس راه‌حل‌ها (واگرایی واترشتاین) و در نهایت معیارهای ارزیابی مدرن (precision/recall) بررسی می‌کنیم.

الف) واگرایی‌های f و رفتار بهینه‌ساز

ایده‌ی کلیدی f-GAN (نووزین و همکاران، ۲۰۱۶) این است که هر واگرایی f بین دو توزیع P و Q یک کران پایین تغییراتی از طریق مزدوج فنچل f^* دارد:

$$D_f(P\|Q) \geq \sup_{T \in \mathcal{T}} \Big[{}_{x\sim P}[T(x)] - {}_{x\sim Q}\left[f^*(T(x))\right] \Big].$$

(آ) برای واگرایی KL با $f(u) = u \log u$، مزدوج فنچل $f^*(v)$ را محاسبه کنید و نشان دهید $D_f(P\|Q) = D_{\mathrm{KL}}(P\|Q)$. سپس برای دو گاوسی هم‌واریانس $P = (\mu_1, \sigma^2 I)$ و $Q = (\mu_2, \sigma^2 I)$ ثابت کنید:

$$D_{\mathrm{KL}}(P\|Q) = \frac{\|\mu_1 - \mu_2\|^2}{2\sigma^2}.$$

(ب) چارچوب f-GAN نشان می‌دهد که انتخاب f تعیین می‌کند مدل «میانگین‌گرا» (mean-seeking) باشد یا «مدگرا» (mode-seeking). فرض کنید $P = \frac{1}{K}\sum_{k=1}^{K}(\mu_k, \sigma^2 I)$ یک مخلوط K–مدی و $Q = (\mu, \sigma^2 I)$ یک گاوسی تک‌مدی باشد.

(آ) کدام یک از واگرایی‌های $D_{\mathrm{KL}}(P\|Q)$ یا $D_{\mathrm{KL}}(Q\|P)$ باعث می‌شود Q در میانگین $\bar{\mu} = \frac{1}{K}\sum_k \mu_k$ متمرکز شود؟ μ را محاسبه کنید.

(ب) کدام یک باعث می‌شود Q به یکی از مدهای μ_k فروبپاشد؟ چرا GAN استاندارد (مبتنی بر JS که میانگینی از دو جهت KL است) بیشتر تمایل به **مدگرا** دارد؟

(ج) جدول زیر از مقاله‌ی f-GAN (نووزین و همکاران، ۲۰۱۶، جداول ۱ و ۲) اقتباس شده است. با استفاده از این جدول توضیح دهید:

(الف) چرا برای واگرایی GAN (JS) دامنه‌ی f^* محدود به $t < 0$ است؟ (راهنمایی: با مشتق‌گیری از $f(u)$ در جدول، نشان دهید $T^*(x) = f'(p/q) = \log \frac{p}{p+q}$ و استدلال کنید چرا این مقدار همواره منفی است.) این محدودیت چه پیامدی برای پایداری آموزش دارد؟

(ب) برای واگرایی دلخواهی از جدول (غیر از KL)، با استفاده از $T^*(x) = f'(p/q)$ نشان دهید که چرا مقادیر $f'(u)$ در جدول با ستون «دامنه» سازگار است.

واگرایی	مولد $f(u)$	مزدوج $f^*(t)$	دامنه $\mathrm{dom}(f^*)$
KL	$u \log u$	$\exp(t-1)$	$\mathbb{R}$
KL معکوس	$-\log u$	$-1 - \log(-t)$	$\mathbb{R}^-$
پیرسن χ^2	$(u-1)^2$	$\frac{1}{4}t^2 + t$	$\mathbb{R}$
GAN (JS)	$u\log u - (u+1)\log(u+1)$	$-\log(1-e^t)$	$t < 0$

ب) تفکیک‌گر بهینه، اشباع JS، و واگرایی واترشتاین

(آ) **(۳ نمره)** برای GAN استاندارد با خطای آنتروپی متقاطع دودویی:

$$L_D = {}_{x\sim P}\left[\log D(x)\right] + {}_{x\sim Q}\left[\log(1 - D(x))\right],$$

نشان دهید تفکیک‌گر بهینه (برای Q ثابت) برابر است با:

$$D^*(x) = \frac{p(x)}{p(x) + q(x)}.$$

سپس ثابت کنید در بهینگی:

$$L_D^* = -\log 4 + 2\, D_{\mathrm{JS}}(P\|Q).$$

چرا جمله‌ی $-\log 4$ برای درک **اشباع** (saturation) مهم است؟

(ب) فرض کنید $P = \delta_{x_1}$ و $Q = \delta_{x_2}$ با $x_1 \neq x_2$ دو دلتای دیراک باشند.

(آ) نشان دهید $D_{\mathrm{JS}}(P\|Q) = \log 2$ صرف‌نظر از $\|x_1 - x_2\|$.

(ب) نشان دهید فاصله‌ی واترشتاین‌ـ۱ برابر است با $W_1(P,Q) = \|x_1 - x_2\|$.

(ج) تعمیم دهید: اگر $\mathrm{supp}(P) \cap \mathrm{supp}(Q) = \emptyset$، چرا D_{JS} گرادیان صفر تولید می‌کند (اشباع) ولی W_1 گرادیان معنادار دارد؟

(ج) WGAN با استفاده از دوگان کانتوروویچ‌ـروبینشتاین، W_1 را تقریب می‌زند:

$$W_1(P,Q) = \sup_{\|f\|_L \le 1} {}_P[f(x)] - {}_Q\left[f(x)\right].$$

نشان دهید برای $P = (\mu_P, I)$ و $Q = (\mu_Q, I)$، نگاشت حمل بهینه $T(x) = x + (\mu_P - \mu_Q)$ است و گرادیان به‌روزرسانی مولد در همه‌ی نقاط فضا **یکسان و غیرصفر** است. چرا این ویژگی آموزش WGAN را پایدارتر از GAN استاندارد می‌کند؟

ج) دقت، پوشش، و چرا مدل‌های انتشار بر GAN غلبه کردند

(آ) دواریوال و نیکول (۲۰۲۱) معیارهای **دقت** (precision: کیفیت نمونه‌ها) و **پوشش** (recall: تنوع مدهای پوشش‌داده‌شده) را معرفی کردند. با استفاده از ویژگی‌های واگرایی JS که در بخش‌های قبلی بررسی کردید، توضیح دهید:

(آ) چرا GANها معمولاً دقت بالا ولی پوشش پایین دارند.

(ب) چرا مدل‌های انتشار (Diffusion) معمولاً هر دو را متعادل نگه می‌دارند.

(ج) آیا این یک ویژگی **ذاتی** واگرایی JS است یا صرفاً یک مشکل بهینه‌سازی؟

(ب) یک شبکه‌ی GAN آموزش‌دیده روی ImageNet ممکن است نمونه‌های باکیفیتی از نژاد golden retriever تولید کند اما هرگز سگ نژاد basenji تولید نکند. مدل انتشار با همان تعداد پارامتر چگونه از این مشکل اجتناب می‌کند؟ یک استدلال سه‌مرحله‌ای ساختاریافته ارائه دهید:

(آ) GANها نسبت چگالی $p(x)/q(x)$ را تخمین می‌زنند — یک طبقه‌بندی که در نواحی کم‌چگالی اشباع می‌شود.

(ب) مدل‌های انتشار تابع امتیاز $\nabla \log p_t(x)$ را یاد می‌گیرند — یک رگرسیون که در همه‌جای فضا جهت رشد چگالی را نشان می‌دهد.

(ج) بنابراین وقتی مدل انتشار یک مد را از دست می‌دهد، امتیاز هنوز آن را به سمت مد داده **هل می‌دهد**، در حالی که گرادیان GAN صفر می‌شود.

د) طراحی: انتخاب معیار و تابع هدف مناسب

(آ) دو سناریوی قبلی را کنار هم بگذارید تا یک مقایسه‌ی ساختاری بین W و D_{JS} انجام دهید:

(الف) برای دو گاوسی هم‌پوشان $P = (0, \sigma^2 I)$ و $Q_\theta = (\theta, \sigma^2 I)$ در بخش الف محاسبه کردید که $D_{\mathrm{KL}}(P\|Q_\theta) = \frac{\|\theta\|^2}{2\sigma^2}$. نشان دهید $W_2^2(P, Q_\theta) = \|\theta\|^2$ دقیقاً و توضیح دهید چرا هر دو تابع «خوش‌رفتار» هستند وقتی توزیع‌ها هم‌پوشانی دارند (یعنی هم D_{KL} و هم W_2 به صورت $\|\theta\|^2 \propto$ رشد می‌کنند و گرادیان غیرصفر در $\theta \neq 0$ دارند).

(ب) برای دو دلتای دیراک مجزا $P = \delta_{x_1}$ و $Q = \delta_{x_2}$ با $x_1 \neq x_2$ در بخش ب محاسبه کردید که $D_{\mathrm{JS}}(P\|Q) = \log 2$ (ثابت، گرادیان صفر) و $W_1(P, Q) = \|x_1 - x_2\|$ (خطی، گرادیان معنادار). توضیح دهید چرا این تفاوت برای آموزش GAN روی داده‌های با پشتیبان کم‌بعد (low-dimensional manifold) حیاتی است و چگونه WGAN این مشکل را حل می‌کند.

(ج) با توجه به دو مورد بالا، چرا **چشم‌انداز خطا** (loss landscape) برای GAN مبتنی بر JS در نواحی دور از بهینگی «مسطح» (flat) است در حالی که برای WGAN شیب‌دار باقی می‌ماند؟

(ب) فرض کنید می‌خواهید یک سیستم تولید تصویر بسازید که باید در عین حال **کیفیت بالا** و **پوشش کامل** مدهای داده را داشته باشد. با توجه به آنچه در این پرسش آموختید:

(آ) اگر مجبور به استفاده از GAN باشید، چه تغییری در تابع هدف (واگرایی) پیشنهاد می‌دهید تا فروپاشی مد کاهش یابد؟

(ب) اگر محدودیتی در محاسبه نداشته باشید، چرا مدل انتشار گزینه‌ی بهتری است؟

(ج) برای ارزیابی مدل، چرا معیار FID به تنهایی کافی نیست و باید از Precision/Recall استفاده کرد؟

پاسخ. ▷

الف)

(آ) **مزدوج فنچل برای :KL** برای $f(u) = u\log u$، مزدوج فنچل عبارت است از:

$$f^*(v) = \sup_{u\geq 0}\{vu - u\log u\}.$$

مشتق نسبت به u: $v - \log u - 1 = 0 \Rightarrow u^* = e^{v-1}$. جایگذاری:

$$f^*(v) = ve^{v-1} - e^{v-1}(v-1) = e^{v-1}.$$

بنابراین $D_f(P\|Q) =_P [\log(p/q)] = D_{\mathrm{KL}}(P\|Q)$. برای گاوسی‌های هم‌واریانس $\Sigma_P = \Sigma_Q = \sigma^2 I$:

$$D_{\mathrm{KL}}(P\|Q) = \frac{1}{2}\Big[(I) - d + \frac{\|\mu_1-\mu_2\|^2}{\sigma^2} + 0\Big] = \frac{\|\mu_1-\mu_2\|^2}{2\sigma^2}.$$

(ب) **میانگین‌گرا در مقابل مدگرا:**

(آ) **KL پیشرو** $D_{\mathrm{KL}}(P\|Q)$ میانگین‌گرا است. برای $Q = (\mu, \sigma^2 I)$:

$$\nabla_\mu D_{\mathrm{KL}}(P\|Q) =_P \left[\frac{\mu - x}{\sigma^2}\right] = \frac{\mu - \bar{\mu}}{\sigma^2} = 0 \Rightarrow \mu^* = \bar{\mu}.$$

بنابراین Q در میانگین مدهای P متمرکز می‌شود.

(ب) **KL معکوس** $D_{\mathrm{KL}}(Q\|P)$ مدگرا است. چون $-_Q[\log p(x)]$ باید کمینه شود و $\log p(x)$ در هر یک از مدهای μ_k بیشینه دارد، Q به یکی از مدهای P فرو می‌پاشد. واگرایی JS به صورت:

$$D_{\mathrm{JS}}(P\|Q) = \frac{1}{2}D_{\mathrm{KL}}(P\|M) + \frac{1}{2}D_{\mathrm{KL}}(Q\|M), \quad M = \frac{P+Q}{2},$$

ترکیبی از دو جهت KL است و تمایل قوی به مدگرا دارد، زیرا وقتی Q روی یک مد متمرکز است، گرادیان برای جابه‌جایی به مد دیگر از ناحیه‌ی کم‌چگالی عبور می‌کند که در آنجا JS اشباع شده و گرادیان صفر است.

(ج) **جدول واگرایی‌ها و محدودیت دامنه: (الف)** برای GAN، (JS) $f(u) = u\log u - (u+1)\log(u+1)$. مشتق: $f'(u) = \log u + 1 - (\log(u+1)+1) = \log\frac{u}{u+1}$. رابطه‌ی $T^*(x) = f'(p/q)$ نشان می‌دهد $T^*(x) = \log\frac{p/q}{p/q+1} = \log\frac{p}{p+q}$. چون $p, q \geq 0$ و $p < p+q$ (مگر در نقاطی که $q = 0$)، داریم $\frac{p}{p+q} \in [0,1)$ و بنابراین $T^*(x) = \log\frac{p}{p+q} < 0$ همواره. این یعنی تابع مزدوج $f^*(t) = -\log(1-e^t)$ تنها برای $t < 0$ تعریف می‌شود. اگر ناقد (T) در طول آموزش مقادیر مثبت تولید کند، $f^*(T)$ تعریف نشده (حقیقی نمی‌ماند) و آموزش ناپایدار می‌شود. در عمل، از تابع فعال‌سازی $g_f(v) = -\log(1+e^{-v})$ در لایه‌ی خروجی تفکیک‌گر استفاده می‌شود که به طور خودکار $T(x) \in (-\infty, 0)$ را تضمین می‌کند (Nowozin et al.، ۲۰۱۶، جدول ۲).

(ب) برای χ^2 Pearson: $f(u) = (u-1)^2$، بنابراین $f'(u) = 2(u-1)$ و $T^*(x) = 2(p/q - 1)$ که می‌تواند هر مقدار حقیقی باشد — سازگار با $\mathrm{dom}(f^*) = \mathbb{R}$.

ب)

(آ) **تفکیک‌گر بهینه و اشباع :JS** برای Q ثابت، L_D نسبت به D بیشینه می‌شود:

$$\frac{\delta L_D}{\delta D} = \frac{p(x)}{D(x)} - \frac{q(x)}{1-D(x)} = 0 \Rightarrow D^*(x) = \frac{p(x)}{p(x)+q(x)}.$$

در D^*:

$$L_D^* =_P \Big[\log \frac{p}{p+q}\Big] +_Q \Big[\log \frac{q}{p+q}\Big].$$

از طرفی $D_{\mathrm{JS}}(P\|Q) = \frac{1}{2}{}_P[\log \frac{2p}{p+q}] + \frac{1}{2}{}_Q[\log \frac{2q}{p+q}]$. بنابراین:

$$L_D^* = 2D_{\mathrm{JS}}(P\|Q) +_P [\log \tfrac{1}{2}] +_Q [\log \tfrac{1}{2}] = 2D_{\mathrm{JS}}(P\|Q) - 2\log 2 = 2D_{\mathrm{JS}}(P\|Q) - \log 4.$$

جمله‌ی $-\log 4$ حیاتی است: وقتی $P = Q$، $D_{\mathrm{JS}} = 0$ و $L_D^* = -\log 4$، نه صفر. اگر $-\log 4$ را فراموش کنید، تصور می کنید وقتی تفکیک‌گر کاملاً گمراه می‌شود ($D = 1/2$)، هدف صفر است، در حالی که واقعاً $-\log 4$ است. این جابه‌جایی دیدگاه باعث می‌شود اشباع JS درک شود: وقتی تفکیک‌گر کامل است (D_{JS} بالا)، گرادیان به صفر میل می‌کند.

(ب) **دلتاهای دیراک:**

(آ) $M = \frac{P+Q}{2}$ جرم $\frac{1}{2}$ در x_1 و $\frac{1}{2}$ در x_2 دارد:

$$D_{\mathrm{JS}} = \frac{1}{2}\Big[\frac{1}{2}\log\frac{1}{1/2} + \frac{1}{2}\log\frac{1}{1/2}\Big] = \log 2.$$

این مقدار صرف‌نظر از فاصله‌ی $\|x_1 - x_2\|$ ثابت است.

(ب) تنها جفت‌سازی ممکن $\gamma = \delta_{(x_1,x_2)}$ است:

$$W_1(P,Q) =_\gamma [\|x - y\|] = \|x_1 - x_2\|.$$

(ج) وقتی $\mathrm{supp}(P) \cap \mathrm{supp}(Q) = \emptyset$، برای هر x یا $p(x) = 0$ یا $q(x) = 0$. بنابراین $D^*(x) \in \{0, 1\}$ و $D_{\mathrm{JS}} = \log 2$ ثابت است. گرادیان نسبت به پارامترهای مولد صفر است — پدیده‌ی **اشباع** و **ناپدید شدن گرادیان**. در مقابل، W_1 با فاصله‌ی بین توزیع‌ها به صورت خطی تغییر می‌کند و همیشه گرادیان معنادار دارد.

(ج) **WGAN و نگاشت حمل بهینه:** برای دو گاوسی با ماتریس کوواریانس یکسان، نگاشت حمل بهینه یک انتقال ساده است: $T(x) = x + (\mu_P - \mu_Q)$. ناقد بهینه (تا یک ثابت) $f^*(x) = (\mu_P - \mu_Q)^\top x$ است. بنابراین:

$$\nabla_x f^*(x) = \mu_P - \mu_Q, \quad \forall x.$$

این بردار ثابت و غیرصفر (مگر در بهینگی) است. برخلاف GAN استاندارد که گرادیان در نواحی مجزا صفر می‌شود، WGAN یک سیگنال یادگیری پایدار در سراسر فضا فراهم می‌کند.

ج)

(آ) **دقت و پوشش:**

(آ) GANها معمولاً دقت بالا و پوشش پایین دارند. واگرایی JS طبقه‌بندی تخاصمی است: تفکیک‌گر می‌تواند با **رد کردن** مدهای کم‌احتمال (افزایش دقت) و پذیرش مدهای پراحتمال برنده شود. این باعث می‌شود مولد روی زیرمجموعه‌ای از مدهای داده متمرکز شود — **پوشش پایین**.

(ب) مدل‌های انتشار تابع امتیاز $\nabla \log p(x)$ را مدل می‌کنند که به **همه‌ی نواحی** فضا جهت می‌دهد — حتی نواحی کم‌چگالی. بنابراین پوشش بالا دارند.

(ج) این یک ویژگی **ذاتی** واگرایی JS است، نه فقط یک مشکل بهینه‌سازی. حتی با بهینه‌سازی کامل، JS تمایل به مدگرا دارد (بخش الف–ب).

(ب) **چرا مدل انتشار از فروپاشی مد اجتناب می‌کند:**

(آ) GANها نسبت چگالی $p(x)/q(x)$ را تخمین می‌زنند — یک طبقه‌بندی که در نواحی کم‌چگالی اشباع می‌شود. وقتی تفکیک‌گر تصمیم بگیرد «basenji» را جعلی بداند، گرادیان صفر می‌شود و مولد هرگز آن ناحیه را اکتشاف نمی‌کند.

(ب) مدل‌های انتشار تابع امتیاز $\nabla \log p_t(x)$ را یاد می‌گیرند — یک رگرسیون که در همه‌جای فضا جهت رشد چگالی را نشان می‌دهد. حتی در نواحی کم‌چگالی، $\nabla \log p_t(x)$ جهت نزدیک‌ترین مد داده را نشان می‌دهد.

(ج) بنابراین وقتی مدل انتشار یک مد را از دست می‌دهد، امتیاز هنوز آن را به سمت مد داده **هل می‌دهد**، در حالی که گرادیان GAN صفر می‌شود.

د)

(آ) **مقایسه‌ی ساختاری W و D_{JS}:**

(آ) **گاوسی‌های هم‌پوشان:** برای دو گاوسی با کوواریانس یکسان $\sigma^2 I$، جفت‌سازی حمل بهینه $T(x) = x + \theta$ است که P را به Q_θ منتقل می‌کند. بنابراین:

$$W_2^2(P, Q_\theta) =_{x\sim P} [\|(x+\theta) - x\|^2] = \|\theta\|^2.$$

هر دو تابع D_{KL} و W_2 به صورت $\propto \|\theta\|^2$ رشد می‌کنند و گرادیان غیرصفر در $\theta \neq 0$ دارند. این یعنی وقتی توزیع‌ها هم‌پوشانی دارند، هر دو معیار «خوش‌رفتار» هستند.

(ب) **دلتاهای دیراک مجزا:** $D_{\mathrm{JS}} = \log 2$ ثابت است — گرادیان صفر، بهینه‌سازی غیرممکن. $W_1 = \|x_1 - x_2\|$ خطی است — گرادیان معنادار در همه‌جا. برای داده‌های با پشتیبان کم‌بعد (manifold)، توزیع‌ها تقریباً مجزا هستند، بنابراین GAN استاندارد دچار **ناپدید شدن گرادیان** می‌شود. WGAN با کمینه‌سازی W_1 این مشکل را حل می‌کند.

(ج) **چشم‌انداز خطا:** برای GAN مبتنی بر JS، وقتی توزیع‌ها از هم دور هستند، $D_{\mathrm{JS}} \approx \log 2$ و مشتق ≈ 0 — چشم‌انداز **مسطح** (flat) بدون هیچ سیگنال یادگیری. برای WGAN، $W_1 \propto \|\theta\|$ و مشتق $\propto$ const — چشم‌انداز **شیب‌دار** (sloped) با سیگنال یادگیری پایدار. این ویژگی برای آموزش روی داده‌های با پشتیبان کم‌بعد (low-dimensional manifold) حیاتی است.

(ب) **طراحی سیستم:**

(آ) اگر مجبور به استفاده از GAN باشیم، باید واگرایی JS را کنار بگذاریم و از W_1 (WGAN) یا f-هایdivergenc میانگین‌گرا (مثل KL پیشرو) استفاده کنیم. همچنین استفاده از Spectral Normalization برای تضمین قید جهانی ۱-Lipschitz توصیه می‌شود.

(ب) اگر محدودیتی در محاسبه نداشته باشیم، مدل انتشار گزینه‌ی بهتری است زیرا: (۱) پوشش کامل مدها را تضمین می‌کند، (۲) آموزش پایدارتر است (نیاز به equilibrium Nash ندارد)، (۳) قابل کنترل است ،(CFG) و (۴) کیفیت نمونه‌ها از هاGAN پیشی گرفته است.

(ج) FID یک معیار ترکیبی است که هم کیفیت و هم پوشش را در نظر می‌گیرد، اما دو مدل با FID یکسان ممکن است یکی کیفیت بالا/پوشش پایین و دیگری کیفیت متوسط/پوشش بالا داشته باشند. Precision/Recall این ابهام را برطرف می‌کنند: Precision کیفیت را جداگانه اندازه می‌گیرد و Recall تنوع را.

پرسش ۳. استخراج کران پایین شواهدی [۱] و تابع هدف DDPM (۲۰ نمره)

[۱] Evidence Lower Bound (ELBO)

بخش اول

می‌دانیم در فرآیند روبه‌جلو (Forward) DDPM یک زنجیره مارکوفی داریم که به‌تدریج به تصویر ورودی نویز اضافه می‌کند:

$$q(x_{1:T} \mid x_0) = \prod_{t=1}^{T} q(x_t \mid x_{t-1}) \tag{۱}$$

که در آن هر گام روبه‌جلو را یک توزیع گوسی در نظر می‌گیریم:

$$q(x_t \mid x_{t-1}) = \mathcal{N}(x_t; \sqrt{\alpha_t} x_{t-1}, (1-\alpha_t) I) \tag{۲}$$

الف) اما در فرآیند معکوس (Reverse) که به دنبال تخمین توزیع $q(x_{t-1}|x_t)$ هستیم، نمی‌توان به‌طور قطعی گفت که این توزیع نیز گوسی است. چرا؟ با در نظر گرفتن چه شرطی می‌توان این توزیع را نیز گوسی فرض کرد؟

ب) با اینکه تحت شرایط خاص، می‌توان فرض کرد فرآیند معکوس نیز از یک توزیع گوسی پیروی می‌کند، اما این شرط به تنهایی برای بدست آوردن این توزیع و نمونه‌برداری از آن کافی نیست. چرا؟ **راهنمایی**: اثبات کنید توزیع $q(x_{t-1}|x_t)$ Intractable است.

ج) با چه تغییری می شود یک توزیع tracktable ایجاد کرد؟ روابط مورد نیاز را نوشته و توضیح دهید.

بخش دوم

همانطور که در قسمت قبل دیدید، توزیع فرآیند معکوس DDPM باید به‌صورت رابطه زیر بازنویسی شود:

$$q(x_{t-1} \mid x_t, x_0) \tag{۳}$$

الف) نشان دهید که این عبارت یک توزیع گاوسی با بردار میانگین $\tilde{\mu}_t(x_t, x_0)$ و ماتریس کوواریانس $\tilde{\beta}_t \mathbf{I}$ است که روابط صریح آن‌ها به صورت زیر تعریف می‌شوند:

$$\tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$$
$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}x_0$$

به‌صورت کامل و گام‌به‌گام مسیر رسیدن به این روابط صریح را به‌دست آورید.

ب) در ادامه از کران پایین شواهدی (ELBO) برای $\log p_\theta(x_0)$ شروع کنید و نشان دهید که تابع هدف آموزش [۲] به صورت مجموعی از جمله‌های واگرایی KL [۳] تجزیه می‌شود. سپس ثابت کنید که وقتی واریانس فرایند معکوس برابر با $\tilde{\beta}_t$ در نظر گرفته شود، کمینه کردن این واگرایی KL معادل با کمینه کردن خطای مجذور میانگین وزنی بین $\mu_\theta(x_t, t)$ و $\tilde{\mu}_t(x_t, x_0)$ خواهد بود. هر یک از جملات عبارت به‌دست آمده را تحلیل کنید و نقش آن را در تابع هدف آموزش توضیح دهید

ج) فرض کنید μ_θ از طریق یک noise predictor به صورت $\varepsilon_\theta(x_t, t)$ به شکل زیر پارامتریزه شده است:

[۲] Objective Function
[۳] Kullback–Leibler Divergence

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}} \varepsilon_\theta(x_t, t) \right)$$

نشان دهید که تابع هدف KL در هر گام به‌صورت زیر درمی‌آیند:

$$\mathbb{E}_{x_0,\varepsilon,t}\left[\lambda_t \|\varepsilon - \varepsilon_\theta(x_t, t)\|^2\right] \quad (۴)$$

به‌طور دقیق ضریب وابسته به گام زمانی λ_t را استخراج کنید.

د) همان‌طور که در قسمت قبل نشان دادید، تابع هدف اصلی که از کران پایین شواهدی (ELBO) به دست می‌آید، دارای یک ضریب وزن‌دهی وابسته به زمان است. اما نویسندگان مقاله اصلی DDPM نشان دادند که استفاده از یک تابع هدف ساده‌شده که این ضریب در آن نادیده گرفته شده و معادل ۱ فرض می‌شود ($\lambda_t = 1$)، نتایج بهتری به همراه دارد:

$$L_{simple} = \mathbb{E}_{x_0,\varepsilon,t}\left[\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2\right] \quad (۵)$$

با توجه به رابطه ریاضی ضریب λ_t که در قسمت قبل استخراج کردید، به سوالات زیر پاسخ دهید:

۱. قرار دادن $\lambda_t = 1$ در تابع هدف ساده‌شده، چگونه تمرکزِ تابع هزینه را در گام‌های زمانی مختلف (مراحل با نویز کم یا t کوچک در برابر مراحل با نویز زیاد یا t بزرگ) نسبت به تابع هدف اصلی (ELBO) تغییر می‌دهد؟

۲. با توجه به مفهوم مراحل مختلف نویزگذاری در شکل‌گیری تصاویر، توضیح دهید که چرا این ساده‌سازی و تغییرِ تمرکز، در عمل منجر به تولید نمونه‌هایی با کیفیت بهتر توسط شبکه عصبی می‌شود؟

پاسخ. ◁

بخش اول

الف) توزیع معکوس $q(x_{t-1} \mid x_t)$ بر اساس قانون بیز متناسب با عبارت زیر است:

$$q(x_{t-1} \mid x_t) \propto q(x_t \mid x_{t-1}) q(x_{t-1})$$

اگرچه جمله اول، یعنی $q(x_t \mid x_{t-1})$، طبق تعریف فرآیند روبه‌جلو یک توزیع کاملاً گوسی است، اما جمله دوم، یعنی $q(x_{t-1})$، توزیعی پیچیده و نامشخص است که مستقیماً به توزیع داده‌های واقعی $q(x_0)$ بستگی دارد. از آنجا که ضرب یک توزیع گوسی در یک توزیع پیچیده و نامشخص لزوماً به یک توزیع گوسی منجر نمی‌شود، نمی‌توان به‌طور قطعی گفت که توزیع معکوس نیز گوسی است.

شرط گوسی فرض کردن توزیع معکوس:

تنها در صورتی می‌توان توزیع معکوس را گوسی فرض کرد که اندازه گام‌های زمانی اضافه کردن نویز بسیار کوچک باشد. به بیان ریاضی، اگر میزان نویز اضافه شده در هر گام بسیار ناچیز باشد ($\beta_t = 1 - \alpha_t \to 0$)، توزیع معکوس $q(x_{t-1} \mid x_t)$ به یک توزیع گوسی میل می‌کند. دلیل این امر آن است که وقتی واریانس نویز (β_t) بسیار ناچیز باشد، توزیع گوسیِ $q(x_t \mid x_{t-1})$ رفتاری شبیه به تابع توزیع دلتای دیراک [۴] از خود نشان می‌دهد. ضرب کردن این توزیع گوسی با واریانس بسیار کم در توزیع پیچیده $q(x_{t-1})$، باعث می‌شود توزیع حاصل در یک همسایگی بسیار کوچک،

[۴] Dirac delta function

هموار [۵] شود. در نتیجه، این توزیعِ هموار شده را می‌توان با دقت بسیار بالایی یک توزیع گوسی در نظر گرفت. این شرایط معادل با در نظر گرفتن تعداد گام‌های بسیار زیاد ($T \to \infty$) در فرآیند انتشار است.

ب) برای محاسبه دقیق توزیع $q(x_{t-1} \mid x_t)$ با استفاده از قانون بیز، نیاز به محاسبه مخرج کسر یعنی $q(x_t)$ داریم:

$$q(x_{t-1} \mid x_t) = \frac{q(x_t \mid x_{t-1})q(x_{t-1})}{q(x_t)}$$

عبارت $q(x_t)$ از طریق حاشیه‌گیری [۶] روی توزیع داده‌های اولیه به دست می‌آید:

$$q(x_t) = \int q(x_t \mid x_0)q(x_0)dx_0$$

این انتگرال به دو دلیل اصلی غیرقابل محاسبه (Intractable) است:

۱. **عدم دسترسی به توزیع $q(x_0)$:** ما فرمول ریاضی و دقیق توزیع واقعی داده‌ها ($q(x_0)$) را نداریم و فقط نمونه‌هایی از آن (مجموعه داده آموزشی) در اختیار ماست.

۲. **ابعاد بالا:** فضای داده‌ها (مثل تصاویر) دارای ابعاد بسیار بالایی است و محاسبه انتگرال در چنین فضای چندبعدی‌ای عملاً غیرممکن است.

به دلیل Intractable بودن این انتگرال، نمی‌توان فرمول دقیقی برای $q(x_{t-1} \mid x_t)$ به دست آورد.

ج) برای حل مشکل Intractable بودن توزیع معکوس $q(x_{t-1} \mid x_t)$، ما این توزیع را به داده اولیه یعنی x_0 مشروط (Condition) می‌کنیم. با اضافه کردن شرط x_0، توزیع معکوس به شکل $q(x_{t-1} \mid x_t, x_0)$ در می‌آید که کاملاً قابل محاسبه (Tractable) است.
با استفاده از قانون بیز و ویژگی زنجیره مارکوف (که $q(x_t \mid x_{t-1}, x_0) = q(x_t \mid x_{t-1})$ است)، داریم:

$$q(x_{t-1} \mid x_t, x_0) = \frac{q(x_t \mid x_{t-1}, x_0)q(x_{t-1} \mid x_0)}{q(x_t \mid x_0)} = \frac{q(x_t \mid x_{t-1})q(x_{t-1} \mid x_0)}{q(x_t \mid x_0)}$$

از آنجا که در فرآیند روبه‌جلو، توزیع هر گام به شرط x_0 یک توزیع گوسی خوش‌تعریف است، با مشروط کردن $q(x_{t-1} \mid x_t)$ به x_0، توزیع معکوس فرم بسته (Closed-form) پیدا کرده و Tractable می‌شود و شبکه عصبی می‌تواند یاد بگیرد که این توزیع گوسی را با پیش‌بینی x_0 (یا نویز ϵ) تقریب بزند.

بخش دوم

الف) از قسمت قبل دریافتیم که به کمک قانون بیز، رابطه $q(x_{t-1} \mid x_t, x_0)$ به شکل زیر در می‌آید:

$$q(x_{t-1} \mid x_t, x_0) = \frac{q(x_t \mid x_{t-1})q(x_{t-1} \mid x_0)}{q(x_t \mid x_0)}$$

از فرآیند روبه‌جلو می‌دانیم که تمامی این توزیع‌ها گاوسی هستند:

$$q(x_t \mid x_{t-1}) = \mathcal{N}(x_t; \sqrt{\alpha_t}x_{t-1}, \beta_t\mathbf{I})$$

$$q(x_{t-1} \mid x_0) = \mathcal{N}(x_{t-1}; \sqrt{\bar{\alpha}_{t-1}}x_0, (1 - \bar{\alpha}_{t-1})\mathbf{I})$$

[۵] Smooth
[۶] Marginalization

$$q(x_t \mid x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)\mathbf{I})$$

می‌دانیم که تابع چگالی احتمال یک توزیع گاوسی متناسب با فرم زیر است:

$$\mathcal{N}(x; \mu, \sigma^2\mathbf{I}) \propto \exp\left(-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}\right)$$

اگر مقادیر بالا را در رابطه بیز جایگذاری کنیم و فقط عبارت‌های داخل توان Exponential را بنویسیم، داریم:

$$q(x_{t-1} \mid x_t, x_0) \propto \exp\left(-\frac{1}{2}\left[\frac{(x_t - \sqrt{\alpha_t}x_{t-1})^2}{\beta_t} + \frac{(x_{t-1} - \sqrt{\bar{\alpha}_{t-1}}x_0)^2}{1-\bar{\alpha}_{t-1}} - \frac{(x_t - \sqrt{\bar{\alpha}_t}x_0)^2}{1-\bar{\alpha}_t}\right]\right)$$

از آنجا که هدف ما یافتن توزیع برای متغیر x_{t-1} است، تنها جملاتی که شامل x_{t-1} هستند را نگه می‌داریم و بقیه مقادیر را در یک عبارت ثابت به نام $C(x_t, x_0)$ تجمیع می‌کنیم. با بسط دادن توان‌ها و فاکتورگیری بر اساس x_{t-1} داریم:

$$= \exp\left(-\frac{1}{2}\left[\left(\frac{\alpha_t}{\beta_t} + \frac{1}{1-\bar{\alpha}_{t-1}}\right)x_{t-1}^2 - 2\left(\frac{\sqrt{\alpha_t}}{\beta_t}x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}}x_0\right)x_{t-1} + C(x_t, x_0)\right]\right)$$

حال برای استخراج میانگین ($\tilde{\mu}_t$) و واریانس ($\tilde{\beta}_t$)، به فرم استاندارد تابع چگالی احتمال توزیع گاوسی برمی‌گردیم و توان آن را بسط می‌دهیم:

$$\exp\left(-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}\right) = \exp\left(-\frac{1}{2}\left[\frac{1}{\sigma^2}x^2 - \frac{2\mu}{\sigma^2}x + \frac{\mu^2}{\sigma^2}\right]\right)$$

اگر متغیر x را همان x_{t-1}، پارامتر μ را برابر میانگین مطلوب ما $\tilde{\mu}_t$، و σ^2 را برابر واریانس مطلوب $\tilde{\beta}_t$ در نظر بگیریم، فرم کلی بسط‌یافته باید با معادله‌ای که به دست آوردیم متناسب باشد. به عبارت دیگر، عبارت ما نمایانگر یک توزیع گاوسی است که توان آن متناسب با ساختار زیر است:

$$\exp\left(-\frac{1}{2}\left[\frac{1}{\tilde{\beta}_t}x_{t-1}^2 - \frac{2\tilde{\mu}_t}{\tilde{\beta}_t}x_{t-1} + \dots\right]\right)$$

اکنون با مقایسه ضریب x_{t-1}^2 و ضریب x_{t-1} در دو رابطه بالا، مقادیر واریانس و میانگین را به دست می‌آوریم.
با تطبیق ضرایب x_{t-1}^2 داریم:

$$\frac{1}{\tilde{\beta}_t} = \frac{\alpha_t}{\beta_t} + \frac{1}{1-\bar{\alpha}_{t-1}}$$

با مخرج مشترک‌گیری و توجه به اینکه $\bar{\alpha}_t = \alpha_t\bar{\alpha}_{t-1}$ و $\beta_t = 1 - \alpha_t$:

$$\frac{1}{\tilde{\beta}_t} = \frac{\alpha_t(1-\bar{\alpha}_{t-1}) + \beta_t}{\beta_t(1-\bar{\alpha}_{t-1})} = \frac{\alpha_t - \alpha_t\bar{\alpha}_{t-1} + 1 - \alpha_t}{\beta_t(1-\bar{\alpha}_{t-1})} = \frac{1-\bar{\alpha}_t}{\beta_t(1-\bar{\alpha}_{t-1})}$$

در نتیجه واریانس برابر است با:

$$\tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$$

با تطبیق ضرایب x_{t-1} نیز داریم:

$$\frac{\tilde{\mu}_t}{\tilde{\beta}_t} = \frac{\sqrt{\alpha_t}}{\beta_t}x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}}x_0$$

با ضرب کردن $\tilde{\beta}_t$ در دو طرف معادله و جایگذاری مقدار آن از گام قبل:

$$\tilde{\mu}_t = \left(\frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t\right)\left[\frac{\sqrt{\alpha_t}}{\beta_t}x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}}x_0\right]$$

با ضرب کردن عبارت در داخل کروشه:

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}x_0$$

بدین ترتیب اثبات می‌شود که توزیع $q(x_{t-1} \mid x_t, x_0)$ یک توزیع گاوسی $\mathcal{N}(x_{t-1}; \tilde{\mu}_t, \tilde{\beta}_t\mathbf{I})$ با مقادیر صریح فوق است.

ب) برای رسیدن به تابع هدف در مدل‌های انتشار دیفیوژن و اثبات معادل بودن آن با خطای مجذور میانگین ،(MSE) مراحل را از تعریف کران پایین شواهدی (ELBO) آغاز می‌کنیم.

۱. استخراج ELBO برای لگاریتم درست‌نمایی

هدف ما بیشینه کردن لگاریتم احتمال حاشیه‌ای داده‌های واقعی یعنی $\log p_\theta(x_0)$ است. از آنجا که محاسبه مستقیم این مقدار غیرممکن است، با استفاده از متغیرهای پنهان $x_{1:T}$ و نامساوی جنسن [۷]، کران پایین شواهدی (ELBO) را تشکیل می‌دهیم:

$$\log p_\theta(x_0) = \log \int p_\theta(x_{0:T})\, dx_{1:T} = \log \int q(x_{1:T} \mid x_0)\frac{p_\theta(x_{0:T})}{q(x_{1:T} \mid x_0)}\, dx_{1:T}$$

با اعمال نامساوی جنسن برای توابع مقعر ($\log \mathbb{E}[.] \geq \mathbb{E}[\log .]$) داریم:

$$\log p_\theta(x_0) \geq \mathbb{E}_{q(x_{1:T}|x_0)}\left[\log \frac{p_\theta(x_{0:T})}{q(x_{1:T} \mid x_0)}\right] \tag{۶}$$

با توجه به ویژگی مارکوف، توزیع مشترک فرآیند معکوس p_θ و فرآیند انتشار q به صورت زیر بسط داده می‌شوند:

$$p_\theta(x_{0:T}) = p_\theta(x_T)\prod_{t=1}^{T} p_\theta(x_{t-1} \mid x_t)$$

$$q(x_{1:T} \mid x_0) = \prod_{t=1}^{T} q(x_t \mid x_{t-1}, x_0)$$

با جایگذاری این دو عبارت در رابطه ۶ داریم:

$$\mathbb{E}_q\left[\log \frac{p_\theta(x_T)\prod_{t=1}^{T} p_\theta(x_{t-1} \mid x_t)}{\prod_{t=1}^{T} q(x_t \mid x_{t-1}, x_0)}\right] \tag{۷}$$

با استفاده از قانون بیز، فرآیند روبه‌جلو را به صورت زیر تجزیه می‌کنیم:

$$q(x_t \mid x_{t-1}, x_0) = \frac{q(x_{t-1} \mid x_t, x_0)q(x_t \mid x_0)}{q(x_{t-1} \mid x_0)}$$

[۷] Jensen's inequality

اکنون این کسر را در مخرج رابطه ۷ جایگذاری می‌کنیم. حاصل‌ضرب مخرج به شکل زیر در می‌آید:

$$\prod_{t=1}^{T} q(x_t \mid x_{t-1}, x_0) = \prod_{t=1}^{T} \frac{q(x_{t-1} \mid x_t, x_0) q(x_t \mid x_0)}{q(x_{t-1} \mid x_0)}$$

بخش مربوط به توزیع‌های حاشیه‌ای $\frac{q(x_t|x_0)}{q(x_{t-1}|x_0)}$ دارای خاصیت تلسکوپی است. اگر این حاصل‌ضرب را باز کنیم:

$$\prod_{t=1}^{T} \frac{q(x_t \mid x_0)}{q(x_{t-1} \mid x_0)} = \frac{q(x_1 \mid x_0)}{q(x_0 \mid x_0)} \times \frac{q(x_2 \mid x_0)}{q(x_1 \mid x_0)} \times \cdots \times \frac{q(x_T \mid x_0)}{q(x_{T-1} \mid x_0)}$$

همه عبارات صورت و مخرج به جز جمله آخر کسر (و با در نظر گرفتن $q(x_0 \mid x_0) = 1$) با هم خط می‌خورند و نتیجه برابر می‌شود با: $q(x_T \mid x_0)$. در نتیجه مخرج نهایی به شکل زیر ساده می‌شود:

$$\prod_{t=1}^{T} q(x_t \mid x_{t-1}, x_0) = q(x_T \mid x_0) \prod_{t=1}^{T} q(x_{t-1} \mid x_t, x_0)$$

۲. تجزیه به جملات واگرایی KL

حال عبارت تلسکوپی ساده‌شده را به جای مخرج در رابطه ۷ قرار می‌دهیم:

$$L_{VLB} = \mathbb{E}_q \left[\log \frac{p_\theta(x_T) \prod_{t=1}^{T} p_\theta(x_{t-1} \mid x_t)}{q(x_T \mid x_0) \prod_{t=1}^{T} q(x_{t-1} \mid x_t, x_0)} \right]$$

لگاریتم را پخش کرده و جملات را از هم جدا می‌کنیم (با جدا کردن گام $t = 1$):

$$L_{VLB} = \mathbb{E}_q \left[\log \frac{p_\theta(x_T)}{q(x_T \mid x_0)} + \sum_{t=2}^{T} \log \frac{p_\theta(x_{t-1} \mid x_t)}{q(x_{t-1} \mid x_t, x_0)} + \log \frac{p_\theta(x_0 \mid x_1)}{q(x_0 \mid x_1, x_0)} \right]$$

با توجه به تعریف واگرایی KL که $D_{KL}(q \parallel p) = \mathbb{E}_q \left[\log \frac{q}{p} \right] = -\mathbb{E}_q \left[\log \frac{p}{q} \right]$ است، تابع هدف ما (که برای کمینه کردن به منفی آن یعنی Loss نیاز داریم) به فرم زیر تجزیه می‌شود:

$$Loss = \underbrace{D_{KL}(q(x_T \mid x_0) \parallel p_\theta(x_T))}_{L_T} + \sum_{t=2}^{T} \underbrace{D_{KL}(q(x_{t-1} \mid x_t, x_0) \parallel p_\theta(x_{t-1} \mid x_t))}_{L_{t-1}} \underbrace{- \log p_\theta(x_0 \mid x_1)}_{L_0}$$

۳. اثبات معادل بودن واگرایی KL با MSE (خطای مجذور میانگین)

جمله کلیدی برای آموزش شبکه عصبی L_{t-1} است:

$$L_{t-1} = D_{KL}(q(x_{t-1} \mid x_t, x_0) \parallel p_\theta(x_{t-1} \mid x_t))$$

در بخش‌های قبل دیدیم که توزیع q گاوسی است و پارامترهای این توزیع را به‌دست آوردیم:

$$q(x_{t-1} \mid x_t, x_0) = \mathcal{N}(x_{t-1}; \tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t I)$$

پس توزیع پیش‌بینی شده توسط شبکه عصبی (با فرض ثابت در نظر گرفتن واریانس برابر با $\tilde{\beta}_t I$) برابر خواهد بود با:

$$p_\theta(x_{t-1} \mid x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \tilde{\beta}_t I)$$

فرمول کلی واگرایی KL بین دو توزیع گاوسی چند متغیره $\mathcal{N}_1(\mu_1, \Sigma_1)$ و $\mathcal{N}_2(\mu_2, \Sigma_2)$ با ابعاد d برابر است با:

$$D_{KL}(\mathcal{N}_1 \parallel \mathcal{N}_2) = \frac{1}{2}\left[\log\frac{|\Sigma_2|}{|\Sigma_1|} - d + \mathrm{Tr}(\Sigma_2^{-1}\Sigma_1) + (\mu_1-\mu_2)^T\Sigma_2^{-1}(\mu_1-\mu_2)\right]$$

در اینجا چون ماتریس‌های کوواریانس با هم برابرند ($\Sigma_1 = \Sigma_2 = \tilde{\beta}_t I$):

$$\log\frac{|\Sigma_2|}{|\Sigma_1|} = \log(1) = 0$$
$$\mathrm{Tr}(\Sigma_2^{-1}\Sigma_1) = \mathrm{Tr}(I) = d$$
$$d - d = 0$$

بنابراین، تنها جمله مربوط به فاصله میانگین‌ها باقی می‌ماند:

$$D_{KL}(\mathcal{N}_1 \parallel \mathcal{N}_2) = \frac{1}{2}(\mu_1-\mu_2)^T(\tilde{\beta}_t I)^{-1}(\mu_1-\mu_2)$$

با جایگذاری $\mu_1 = \tilde{\mu}_t(x_t, x_0)$ و $\mu_2 = \mu_\theta(x_t, t)$، خواهیم داشت:

$$L_{t-1} = \frac{1}{2\tilde{\beta}_t}(\tilde{\mu}_t - \mu_\theta)^T(\tilde{\mu}_t - \mu_\theta) = \frac{1}{2\tilde{\beta}_t}\left\|\tilde{\mu}_t(x_t, x_0) - \mu_\theta(x_t, t)\right\|_2^2$$

همان‌طور که ثابت شد، به دلیل برابر بودن ماتریس‌های کوواریانس این دو توزیع گاوسی، محاسبه واگرایی KL به صورت تحلیلی ساده شده و دقیقاً به محاسبه نرم فاصله یا همان خطای مجذور میانگین (MSE) وزن‌دار بین میانگین واقعی $\tilde{\mu}_t$ و میانگین پیش‌بینی‌شده μ_θ تقلیل می‌یابد.

تحلیل جملات و نقش آن‌ها در تابع هدف آموزش

۱. جمله L_T

این جمله واگرایی KL بین توزیع نهایی فرآیند روبه‌جلو ($q(x_T \mid x_0)$) و توزیع پیشین مدل ($p(x_T)$) را محاسبه می‌کند. از آنجا که فرآیند روبه‌جلو ثابت است و توزیع $p(x_T)$ نیز یک گاوسی استاندارد از پیش تعیین‌شده است، کل این جمله در طول آموزش یک **مقدار ثابت** است. بنابراین، گرادیان آن نسبت به پارامترهای مدل صفر است و در فرآیند بهینه‌سازی نادیده گرفته می‌شود.

۲. جمله L_{t-1}

این جمله تفاوت بین توزیع معکوس واقعی و توزیع تقریب‌زده‌شده توسط شبکه را اندازه‌گیری می‌کند که معادل خطای مجذور میانگین (MSE) است. این جمله تنها بخشی است که پارامترهای شبکه عصبی (θ) را درگیر می‌کند. با کمینه کردن آن، شبکه یاد می‌گیرد نویز اضافه‌شده را به درستی تخمین بزند و حذف کند.

۳. جمله L_0

این جمله نشان‌دهنده لگاریتم احتمال منفی برای آخرین گام فرآیند معکوس است و عملکردی شبیه به تابع هزینه بازسازی در VAE دارد. این بخش به مدل کمک می‌کند تا در گام نهایی، مقادیر دقیق پیکسل‌های داده اصلی را با دقت بالا تولید کند.

ج) همان‌طور که در بخش قبل نشان داده شد، تابع هدف واگرایی KL برای گام t (یعنی L_{t-1}) معادل با خطای مجذور میانگین (MSE) بین میانگین واقعی $\tilde{\mu}_t$ و میانگین پیش‌بینی‌شده μ_θ است:

$$L_{t-1} = \frac{1}{2\tilde{\beta}_t} \|\tilde{\mu}_t(x_t, x_0) - \mu_\theta(x_t, t)\|_2^2$$

برای بازنویسی این تابع هدف بر حسب نویز ε، ابتدا باید میانگین واقعی $\tilde{\mu}_t(x_t, x_0)$ را بر حسب x_t و ε بیان کنیم. در قسمت الف فرمول میانگین واقعی را به صورت زیر به‌دست آوردیم:

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} x_0$$

از فرآیند انتشار رو به جلو می‌دانیم که x_t به صورت زیر با x_0 و نویز افزوده شده $\varepsilon \sim \mathcal{N}(0, I)$ ارتباط دارد:

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t}\,\varepsilon$$

با بازنویسی این رابطه، می‌توانیم x_0 را بر حسب x_t و ε استخراج کنیم:

$$x_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} \left(x_t - \sqrt{1-\bar{\alpha}_t}\,\varepsilon\right)$$

اکنون این عبارت را در رابطه $\tilde{\mu}_t(x_t, x_0)$ جایگذاری می‌کنیم:

$$\begin{aligned}
\tilde{\mu}_t(x_t, x_0) &= \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} \left[\frac{1}{\sqrt{\bar{\alpha}_t}} \left(x_t - \sqrt{1-\bar{\alpha}_t}\,\varepsilon\right)\right] \\
&= \left(\frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{\sqrt{\bar{\alpha}_t}(1-\bar{\alpha}_t)}\right) x_t - \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t\sqrt{1-\bar{\alpha}_t}}{\sqrt{\bar{\alpha}_t}(1-\bar{\alpha}_t)}\,\varepsilon
\end{aligned}$$

با توجه به رابطه $\sqrt{\bar{\alpha}_t} = \sqrt{\alpha_t}\sqrt{\bar{\alpha}_{t-1}}$، کسر دوم در ضریب x_t به شکل $\frac{\beta_t}{\sqrt{\alpha_t}(1-\bar{\alpha}_t)}$ ساده می‌شود. با مخرج مشترک‌گیری و استفاده از $\beta_t = 1 - \alpha_t$، ضریب x_t دقیقاً برابر با $\frac{1}{\sqrt{\alpha_t}}$ خواهد شد. همچنین در ضریب ε با ساده‌سازی $\sqrt{\bar{\alpha}_{t-1}}$ با مخرج، به عبارت $\frac{\beta_t}{\sqrt{\alpha_t}\sqrt{1-\bar{\alpha}_t}}$ می‌رسیم. پس میانگین واقعی به فرم زیر درمی‌آید:

$$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\,\varepsilon\right)$$

طبق فرض سوال، میانگین پیش‌بینی‌شده نیز به همین شکل پارامتریزه شده است:

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\,\varepsilon_\theta(x_t, t)\right)$$

حال هر دو عبارت $\tilde{\mu}_t$ و μ_θ را در تابع هدف L_{t-1} قرار می‌دهیم:

$$\begin{aligned}
L_{t-1} &= \frac{1}{2\tilde{\beta}_t} \left\| \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\,\varepsilon\right) - \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\,\varepsilon_\theta(x_t, t)\right) \right\|_2^2 \\
&= \frac{1}{2\tilde{\beta}_t} \left\| \frac{-1}{\sqrt{\alpha_t}} \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}} (\varepsilon - \varepsilon_\theta(x_t, t)) \right\|_2^2 \\
&= \frac{1}{2\tilde{\beta}_t} \left(\frac{\beta_t^2}{\alpha_t(1-\bar{\alpha}_t)}\right) \|\varepsilon - \varepsilon_\theta(x_t, t)\|_2^2
\end{aligned}$$

با تعریف ضریب λ_t به صورت زیر:

$$\lambda_t = \frac{\beta_t^2}{2\tilde{\beta}_t \alpha_t (1-\bar{\alpha}_t)}$$

تابع هدف نهایی برای هر گام به فرم مطلوب زیر درمی‌آید (با گرفتن امید ریاضی روی تمامی گام‌ها، توزیع داده‌ها و نویز افزوده شده):

$$\mathbb{E}_{x_0,\varepsilon,t}\left[\lambda_t \|\varepsilon - \varepsilon_\theta(x_t, t)\|^2\right]$$

در صورتی که بخواهیم λ_t را بیشتر ساده کنیم، با جایگذاری مقدار تحلیلی واریانس توزیع پسین $\tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$ خواهیم داشت:

$$\lambda_t = \frac{\beta_t^2}{2\left(\frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t\right)\alpha_t(1-\bar{\alpha}_t)} = \frac{\beta_t}{2\alpha_t(1-\bar{\alpha}_{t-1})}$$

بنابراین ضریب وابسته به گام زمانی به‌طور دقیق استخراج شد.
د) در بخش قبل دیدیم که ضریب وزن‌دهی در تابع هدف ELBO به صورت زیر به دست می‌آید:

$$\lambda_t = \frac{\beta_t}{2\alpha_t(1-\bar{\alpha}_{t-1})}$$

برای درک تاثیر $\lambda_t = 1$، باید رفتار λ_t را در گام‌های زمانی مختلف بررسی کنیم:

- **برای tهای کوچک (مراحل با نویز کم):** مقدار $\bar{\alpha}_{t-1}$ بسیار نزدیک به ۱ است، در نتیجه عبارت $(1-\bar{\alpha}_{t-1})$ در مخرج بسیار کوچک خواهد بود. این موضوع باعث می‌شود λ_t در گام‌های اولیه (نزدیک به x_0) مقادیر **بسیار بزرگی** داشته باشد.
- **برای tهای بزرگ (مراحل با نویز زیاد):** مقدار $\bar{\alpha}_{t-1}$ به سمت ۰ میل می‌کند، بنابراین مخرج کسر بزرگ‌تر شده و λ_t مقادیر **بسیار کوچک‌تری** به خود می‌گیرد.

بنابراین، تابع هدف اصلی (ELBO) وزن و تمرکز بسیار زیادی روی tهای کوچک (نویز کم) دارد و گام‌های t بزرگ (نویز زیاد) را کم‌اهمیت در نظر می‌گیرد. هنگامی که از تابع هدف ساده‌شده استفاده می‌کنیم و وزن همه گام‌ها را برابر با ۱ قرار می‌دهیم ($\lambda_t = 1$) در واقع نسبت به تابع ELBO، **وزن گام‌های با نویز کم (تغییرات جزئی) را به شدت کاهش داده و وزن گام‌های با نویز زیاد (ساختارهای کلی) را افزایش می‌دهیم**. این کار باعث توزیع متوازن‌ترِ توجه مدل در طول کل فرآیند می‌شود.
این تغییرِ تمرکز، تاثیر مستقیمی بر کیفیت بصری نمونه‌های تولید شده دارد که با بررسی ماهیت نویز در تصاویر قابل توضیح است:

- **مراحل با نویز زیاد (گام‌های ابتدایی در فرآیند تولید / tهای بزرگ):** در این مراحل، شبکه عصبی در حال یادگیری **ساختار کلی، ترکیب‌بندی و محتوای فرکانس پایین** تصویر است (مانند تشخیص اینکه در تصویر یک سگ وجود دارد یا یک منظره).
- **مراحل با نویز کم (گام‌های انتهایی در فرآیند تولید / tهای کوچک):** در این مراحل، مدل در حال نویززدایی از **جزئیات بسیار ریز و فرکانس بالا** است که تفاوت بین آن‌ها در حد چند پیکسل ناچیز بوده و اغلب توسط چشم انسان قابل تشخیص نیست.

تابع هدف ELBO مدل را مجبور می‌کند بخش عمده‌ای از ظرفیت یادگیری خود را صرف بهینه‌سازی دقیقِ نویزهای فرکانس بالا در tهای کوچک کند (به دلیل وزن بسیار بالای λ_t)، که از نظر ادراکی برای انسان اهمیت چندانی ندارند. در مقابل، استفاده از L_{simple} با متعادل کردن وزن‌ها باعث می‌شود شبکه عصبی تمرکز کافی و بیشتری روی گام‌های t بزرگ بگذارد. در نتیجه، مدل در شکل‌دادن به ساختار کلی و ویژگی‌های ادراکی مهمِ تصویر بهتر عمل کرده و نمونه‌هایی تولید می‌کند که از نظر بصری (برای چشم انسان) یکپارچگی و کیفیت بسیار بالاتری دارند.

پرسش ۴. از تابع امتیاز تا انتشار: رگرسیون، شار احتمال، و نمونه‌برداری سریع (۲۰ نمره)

پیش‌زمینه: پرسش پیشین نشان داد که GANها به دلیل طبقه‌بندی تخاصمی مستعد فروپاشی مد هستند. چارچوب جایگزین — **تطبیق تابع امتیاز** (Score Matching) و **مدل‌های انتشار** (Diffusion) — از **رگرسیون** به جای طبقه‌بندی استفاده می‌کند. این پرسش نشان می‌دهد چرا این تغییر ظاهرا ساده، ریشه‌ی مشکل فروپاشی مد را حذف می‌کند، و چگونه می‌توان نمونه‌برداری از انتشار را تسریع بخشید.

الف) تابع امتیاز، فرمول توییدی، و پایداری در نواحی کم‌چگالی

(آ) وینسنت (۲۰۱۱) نشان داد که **تطبیق تابع امتیاز با نویز** (Denoising Score Matching) معادل آموزش یک بازسازی‌کننده‌ی نویز است. فرض کنید $x = x_0 + \sigma\epsilon$ با $x_0 \sim p$ و $\epsilon \sim (0, I)$. با استفاده از **فرمول توییدی**:

$$[x_0 \mid x] = x + \sigma^2 \nabla \log p(x),$$

نشان دهید تابع امتیاز بهینه برابر است با:

$$s^*(x) = \nabla \log p(x) = \frac{[x_0 \mid x] - x}{\sigma^2}.$$

این یعنی تابع امتیاز تنها با یک تفاضل و یک مقیاس‌دهی از بازسازی‌کننده‌ی نویز به دست می‌آید.

(ب) هدف آموزش بازسازی‌کننده‌ی نویز $\min_{\theta} {}_{x_0,\epsilon}[\|D_\theta(x_0 + \sigma\epsilon) - x_0\|^2]$ یک **مسئله‌ی رگرسیون** است. مقایسه کنید با هدف تفکیک‌گر GAN:

$$\max_D {}_P[\log D(x)] +_Q [\log(1 - D(x))],$$

که یک **مسئله‌ی طبقه‌بندی** است. چرا زمانی که $D^*(x) \approx 1$ (تفکیک‌گر بسیار مطمئن)، گرادیان طبقه‌بندی ناپدید می‌شود، در حالی که حتی اگر بازسازی‌کننده به طور کامل داده را بازسازی کند، گرادیان رگرسیون همچنان معنادار است؟

(ج) فرض کنید مولد در ناحیه‌ای از فضا قرار دارد که داده‌ی آموزشی تقریباً وجود ندارد ($p(x) \approx 0$). نشان دهید که برای تابع امتیاز، حتی در این نواحی $\nabla \log p(x)$ همچنان **جهت رشد چگالی** را نشان می‌دهد — مانند یک **قطب‌نما** به سمت داده. در مقابل، واگرایی JS در این ناحیه گرادیان صفر تولید می‌کند. چرا تابع امتیاز «همه‌جا زنده» است ولی تفکیک‌گر GAN «در بیابان می‌میرد»؟

ب) از ELBO تا پیش‌بینی نویز: مشتق‌گیری ساختاریافته

مدل انتشار یک مدل متغیر پنهان سلسله‌مراتبی است که فرآیند پیشروی (افزودن نویز) ثابت و فرآیند وارونه (حذف نویز) آموزش‌دیدنی است. هدف، بیشینه‌سازی درست‌نمایی حاشیه‌ای $p_\theta(x_0)$ است که از طریق یک کران پایین تغییراتی (ELBO) بهینه می‌شود.

(آ) فرآیند پیشروی در گام t به صورت $q(x_t \mid x_{t-1}) = (x_t; \sqrt{1-\beta_t}\, x_{t-1}, \beta_t I)$ تعریف می‌شود. با استفاده از بازنویسی $\alpha_t := 1 - \beta_t$ و $\bar{\alpha}_t := \prod_{s=1}^{t} \alpha_s$، نشان دهید چگالی حاشیه‌ی شرطی بر حسب x_0 برابر است با:

$$q(x_t \mid x_0) = \Big(x_t; \sqrt{\bar{\alpha}_t}\, x_0, (1 - \bar{\alpha}_t) I\Big).$$

(ب) با استفاده از قاعده‌ی بیز، چگالی وارونه‌ی شرطی $q(x_{t-1} \mid x_t, x_0)$ نیز گاوسی است:

$$q(x_{t-1} \mid x_t, x_0) = (x_{t-1}; \tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t I),$$

که در آن:

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t, \qquad \tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t.$$

مدل وارونه‌ی آموزش‌دیدنی $p_\theta(x_{t-1} \mid x_t) = (x_{t-1}; \mu_\theta(x_t, t), \sigma_t^2 I)$ را در نظر بگیرید. نشان دهید هزینه‌ی $\mathcal{L}_{t-1} =_q [D_{\mathrm{KL}}(q(x_{t-1} \mid x_t, x_0) \| p_\theta(x_{t-1} \mid x_t))]$ معادل است با:

$$\mathcal{L}_{t-1} =_{x_0,\epsilon} \left[\frac{1}{2\sigma_t^2}\left\|\tilde{\mu}_t(x_t(x_0,\epsilon), x_0) - \mu_\theta(x_t(x_0,\epsilon), t)\right\|^2\right] + C.$$

(ج) حال با استفاده از پارامتری‌سازی مجدد $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\,\epsilon$ و انتخاب:

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}}\Big(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(x_t, t)\Big),$$

نشان دهید هدف آموزشی ساده‌شده به فرم زیر درمی‌آید:

$$\mathcal{L}_{\text{simple}} =_{x_0,\epsilon,t} \left[\left\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}\,x_0 + \sqrt{1-\bar{\alpha}_t}\,\epsilon, t)\right\|^2\right].$$

چرا این هدف ساده‌تر از پیش‌بینی مستقیم x_0 یا میانگین $\tilde{\mu}_t$ است؟ (راهنمایی: به مقیاس نویز و پایداری گرادیان فکر کنید.)

ج) DDIM و نمونه‌برداری غیرمارکفی سریع

یک نقص بزرگ DDPM نیاز به $T = 1000$ گام تصادفی برای نمونه‌برداری است. سانگ و همکاران (۲۰۲۱) با معرفی DDIM نشان دادند که می‌توان همان مدل آموزش‌دیده را با گام‌های بسیار کمتر و به صورت **قطعی** نمونه برد.

(آ) در DDPM، فرآیند پیشروی یک زنجیره‌ی مارکفی است و فرآیند وارونه نیز برای تقریب از مارکوف استفاده می‌کند:

$$x_{t-1} = \mu_\theta(x_t, t) + \sigma_t z, \qquad z \sim (0, I).$$

DDIM یک خانواده از فرآیندهای **غیرمارکفی** تعریف می‌کند که همان **حاشیه‌های** $q(x_t \mid x_0)$ را حفظ می‌کنند. معادله‌ی نمونه‌برداری DDIM عبارت است از:

$$x_{t-1} = \sqrt{\bar{\alpha}_{t-1}}\,\hat{x}_0(x_t) + \sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2}\,\epsilon_\theta(x_t, t) + \sigma_t z,$$

که در آن $\hat{x}_0(x_t) = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\,\epsilon_\theta(x_t,t)}{\sqrt{\bar{\alpha}_t}}$. برای حالت خاص $\sigma_t = 0$:

(آ) نشان دهید نمونه‌برداری **قطعی** (deterministic) می‌شود.

(ب) توضیح دهید چرا با وجود غیرمارکفی بودن فرآیند، **تابع هدف آموزش** تغییر نمی‌کند. (راهنمایی: $\mathcal{L}_{\text{simple}}$ فقط به حاشیه‌ی $q(x_t \mid x_0)$ وابسته است، نه به شرطی کامل $q(x_{1:T} \mid x_0)$.)

(ب) سانگ و همکاران (۲۰۲۱) در چارچوب Score-Based Generative Modeling through SDEs نشان دادند که فرآیند پیشروی انتشار را می‌توان به صورت یک معادله‌ی دیفرانسیل تصادفی (SDE) نوشت:

$$dx = f(x,t)\,dt + g(t)\,dW_t.$$

چگالی حاشیه‌ای $p_t(x)$ در معادله‌ی فوکر–پلانک صدق می‌کند. وارون زمانی این SDE عبارت است از:

$$dx = \big[f(x,t) - g(t)^2\nabla_x \log p_t(x)\big]dt + g(t)\,d\bar{W}_t.$$

اگر به جای نویز تصادفی، مسیر **ی‌ODE شار احتمال** (Probability Flow ODE) را دنبال کنیم، چگونه عبارت بالا ساده می‌شود؟ چرا ODE (که قطعی است) برای محاسبه‌ی **درست‌نمایی** مناسب‌تر است، در حالی که SDE برای **نمونه‌برداری** انعطاف‌پذیرتر است؟

د) جمع‌بندی: چرا رگرسیون از طبقه‌بندی بهتر است

(آ) یک استدلال سه‌مرحله‌ای ساختاریافته ارائه دهید که چرا مدل‌های انتشار از فروپاشی مد اجتناب می‌کنند:

(آ) GANها نسبت چگالی $p(x)/q(x)$ را تخمین می‌زنند — یک **طبقه‌بندی** که در نواحی کم‌چگالی اشباع می‌شود.

(ب) مدل‌های انتشار تابع امتیاز $\nabla \log p_t(x)$ را یاد می‌گیرند — یک **رگرسیون** که در همه‌جای فضا جهت رشد چگالی را نشان می‌دهد.

(ج) بنابراین وقتی مدل انتشار یک مد را از دست می‌دهد، امتیاز هنوز آن را به سمت مد داده **هل می‌دهد**، در حالی که گرادیان GAN صفر می‌شود.

این استدلال را با مثال مخلوط دو گاوسی $P = \frac{1}{2}(-\mu, \sigma^2) + \frac{1}{2}(\mu, \sigma^2)$ و یک مولد تک‌مدی $Q_\theta = (\theta, \sigma^2)$ تشریح کنید.

(ب) **طراحی:** فرض کنید می‌خواهید از یک مدل انتشار برای تولید تصویر استفاده کنید. برای هر یک از سناریوهای زیر توضیح دهید کدام روش نمونه‌برداری (DDPM تصادفی در مقابل DDIM قطعی) و چه تعداد گام مناسب است:

(آ) تنوع بالا با اولویت اول (مثلاً برای augmentation.)

(ب) کیفیت بسیار بالا با زمان محاسبه نامحدود (مثلاً تولید اثر هنری نهایی).

(ج) تعادل کیفیت–سرعت (مثلاً نمونه‌برداری تعاملی).

پاسخ. ◁

الف)

(آ) **فرمول توییدی:** برای $x = x_0 + \sigma\epsilon$ با $x_0 \sim p$ و $\epsilon \sim (0, I)$، چگالی x یک میانگین کانولوشنی است: $p(x) = \int p(x_0)(x; x_0, \sigma^2 I)dx_0$. مشتق لگاریتم چگالی:

$$\nabla_x \log p(x) = \frac{\int p(x_0)(x; x_0, \sigma^2 I) \cdot \frac{x_0 - x}{\sigma^2} dx_0}{\int p(x_0)(x; x_0, \sigma^2 I)dx_0} = \frac{[x_0 \mid x] - x}{\sigma^2}.$$

بنابراین تابع امتیاز بهینه برابر است با:

$$s^*(x) = \nabla \log p(x) = \frac{[x_0 \mid x] - x}{\sigma^2} = \frac{D^*(x) - x}{\sigma^2},$$

که $D^*(x) = [x_0 \mid x]$ بازسازی‌کننده‌ی نویز بهینه است.

(ب) **طبقه‌بندی در مقابل رگرسیون:** در طبقه‌بندی GAN، وقتی $D^*(x) \approx 1$ (تفکیک‌گر مطمئن است که x واقعی است)، $\log D^* \approx 0$ و $\nabla \log D^* \approx 0$. بنابراین گرادیان ناپدید می‌شود — سیگنال یادگیری قطع می‌شود. در رگرسیون، حتی اگر $D^*_{\text{score}}(x) = x_0$ کامل باشد، هدف MSE هنوز غیرصفر است زیرا ورودی نویزی $x \neq x_0$ است. گرادیان:

$$\nabla_\theta \|D_\theta(x) - x_0\|^2 = 2(D_\theta(x) - x_0)\nabla_\theta D_\theta(x),$$

همچنان معنادار است — حتی در بهینگی کامل.

(ج) **تابع امتیاز در نواحی کم‌چگالی:** برای تابع امتیاز در ناحیه‌ای که $p(x) \approx 0$:

$$\nabla \log p(x) = \frac{\nabla p(x)}{p(x)}.$$

اگرچه $p(x)$ کوچک است، $\nabla p(x)$ نیز کوچک است، اما نسبت آن‌ها یک **جهت واحد** است که به سمت نزدیک‌ترین مد داده اشاره می‌کند. این مانند یک قطب‌نما است: حتی در بیابان، هنوز جهت شمال را نشان می‌دهد. در مقابل، واگرایی JS در نواحی مجزا صرفاً $\log 2$ است — بدون جهت. بنابراین تابع امتیاز «همه‌جا زنده» است ولی تفکیک‌گر GAN «در بیابان می‌میرد».

ب)

(آ) **چگالی حاشیه‌ی شرطی:** فرآیند پیشروی $q(x_t \mid x_{t-1}) = (\sqrt{\alpha_t}\, x_{t-1}, (1-\alpha_t)I)$ یک گاوسی خطی است. با استفاده از ویژگی کانولوشن گاوسی‌ها، می‌توانیم x_t را به صورت بازنویسی شده بنویسیم:

$$x_t = \sqrt{\alpha_t}\, x_{t-1} + \sqrt{1-\alpha_t}\, \epsilon_{t-1}.$$

با بازگشتی جایگذاری:

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \bar{\epsilon},$$

که $\bar{\epsilon} \sim (0, I)$. بنابراین:

$$q(x_t \mid x_0) = (x_t; \sqrt{\bar{\alpha}_t}\, x_0, (1-\bar{\alpha}_t)I).$$

(ب) **واگرایی KL و میانگین وارونه:** با استفاده از قاعده‌ی بیز:

$$q(x_{t-1} \mid x_t, x_0) = \frac{q(x_t \mid x_{t-1}, x_0) q(x_{t-1} \mid x_0)}{q(x_t \mid x_0)}.$$

هر سه چگالی گاوسی هستند. با انجام محاسبات تکمیل مربع (یا استفاده از فرمول‌های استاندارد بیز برای گاوسی)، به میانگین و واریانس داده شده در سوال می‌رسیم. حال $p_\theta(x_{t-1} \mid x_t) = (\mu_\theta(x_t, t), \sigma_t^2 I)$ را در نظر بگیرید. واگرایی KL دو گاوسی هم‌واریان:

$$D_{\mathrm{KL}}(q \| p_\theta) = \frac{1}{2\sigma_t^2}\, [\|\tilde{\mu}_t - \mu_\theta(x_t, t)\|^2] + C.$$

با نمونه‌برداری از $x_0 \sim q(x_0)$ و $\epsilon \sim (0, I)$ و ساخت $x_t(x_0, \epsilon) = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$:

$$\mathcal{L}_{t-1} =_{x_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \|\tilde{\mu}_t(x_t(x_0, \epsilon), x_0) - \mu_\theta(x_t(x_0, \epsilon), t)\|^2 \right] + C.$$

(ج) **پارامتری‌سازی پیش‌بینی نویز:** با جایگذاری $\tilde{\mu}_t$ و $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$ در عبارت بالا و سپس جایگذاری پارامتری‌سازی μ_θ:

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \Big(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_\theta(x_t, t) \Big),$$

می‌توانیم $\tilde{\mu}_t$ را نیز بر حسب x_t و ϵ بنویسیم. پس از ساده‌سازی جبرایی (که در مقاله‌ی Ho et al. ۲۰۲۰ به تفصیل آمده است)، جملات وابسته به x_t حذف می‌شوند و باقیمانده:

$$\|\tilde{\mu}_t - \mu_\theta\|^2 \propto \|\epsilon - \epsilon_\theta(x_t, t)\|^2.$$

بنابراین:

$$\mathcal{L}_{\text{simple}} =_{x_0, \epsilon, t} \left[\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, t)\|^2 \right].$$

این هدف ساده‌تر است زیرا: (۱) شبکه فقط یک سیگنال نویز استاندارد را پیش‌بینی می‌کند که دینامیک محدودی دارد، (۲) نیازی به پیش‌بینی مستقیم تصویر x_0 نداریم که در گام‌های اولیه (t نزدیک T) بسیار نویزی است، و (۳) ثبات عددی بهتر است چون ϵ همیشه در مقیاس واحد است.

ج)

(آ) **DDIM و نمونه‌برداری قطعی:**

(آ) برای $\sigma_t = 0$:

$$x_{t-1} = \sqrt{\bar{\alpha}_{t-1}}\,\hat{x}_0(x_t) + \sqrt{1-\bar{\alpha}_{t-1}}\,\epsilon_\theta(x_t, t).$$

هیچ جمله‌ی تصادفی z وجود ندارد. بنابراین با شروع از یک x_T ثابت، مسیر تا x_0 کاملاً قطعی است.

(ب) تابع هدف آموزش $\mathcal{L}_{\text{simple}}$ فقط به حاشیه‌ی $q(x_t \mid x_0)$ وابسته است، نه به ساختار کامل زنجیره‌ی مارکفی $q(x_{1:T} \mid x_0)$. چون DDIM حاشیه‌ها را حفظ می‌کند ($q_\sigma(x_t \mid x_0) = (\sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I)$) برای هر σ)، هدف آموزش تغییر نمی‌کند. این نتیجه‌ی کلیدی Theorem ۱ در مقاله‌ی DDIM است.

(ب) **SDE وارونه و ODE: Flow Probability** برای Flow Probability ،ODE نویز تصادفی حذف می‌شود و معادله به صورت:

$$dx = \Big[f(x,t) - \frac{1}{2}g(t)^2\nabla_x \log p_t(x)\Big]dt$$

درمی‌آید. این یک معادله‌ی دیفرانسیل معمولی (ODE) قطعی است.

- **ODE برای درست‌نمایی:** چون مسیر قطعی است، می‌توان از قاعده‌ی تغییر متغیر فوری (instanta - neous change of variables) برای محاسبه‌ی دقیق $\log p(x_0)$ استفاده کرد. این امکان‌پذیر نیست برای SDE که نویز تصادفی دارد.
- **SDE برای نمونه‌برداری:** نویز تصادفی در SDE امکان **گریز از مدهای محلی** (mixing) را فراهم می‌کند و فضای نمونه‌ها را بهتر کاوش می‌کند. در نتیجه کیفیت نمونه‌های SDE معمولاً بهتر از ODE با تعداد گام یکسان است.

د)

(آ) **استدلال سه‌مرحله‌ای:**

(آ) GANها نسبت چگالی $p(x)/q(x)$ را تخمین می‌زنند. این یک طبقه‌بندی است که در نواحی کم‌چگالی (دور از داده) اشباع می‌شود — گرادیان صفر.

(ب) مدل‌های انتشار تابع امتیاز $\nabla \log p_t(x)$ را یاد می‌گیرند. این یک رگرسیون است که در همه‌جا جهت رشد چگالی را نشان می‌دهد — گرادیان پایدار.

(ج) بنابراین وقتی مدل انتشار یک مد را از دست می‌دهد، امتیاز هنوز آن را به سمت مد داده **هل می‌دهد**، در حالی که گرادیان GAN صفر می‌شود.

مثال مخلوط دو گاوسی: اگر θ نزدیک μ باشد، GAN دیگر انگیزه‌ای برای اکتشاف مد $-\mu$ ندارد چون تفکیک‌گر می‌تواند با رد کردن نمونه‌های نزدیک $-\mu$ برنده شود. در مقابل، تابع امتیاز در $-\mu$ هنوز یک گرادیان غیرصفر دارد که مولد را به سمت آن مد هل می‌دهد.

(ب) **طراحی نمونه‌برداری:**

(آ) **تنوع بالا:** از SDE DDPM) تصادفی) با تعداد گام متوسط (مثلاً ۵۰) استفاده کنید. نویز تصادفی امکان گریز از مدهای محلی و کاوش فضای وسیع‌تر را فراهم می‌کند.

(ب) **کیفیت بسیار بالا:** از DDPM با تعداد گام زیاد (۲۵۰-۱۰۰۰) استفاده کنید. SDE با گام‌های زیاد کیفیت بهتری تولید می‌کند زیرا خطای گسسته‌سازی کمتر است.

(ج) **تعادل کیفیت‌ـسرعت:** از ODE DDIM) قطعی) با تعداد گام متوسط (۲۰-۵۰) استفاده کنید. DDIM سرعت بالاتری دارد ولی هنوز کیفیت قابل قبولی تولید می‌کند.

پرسش ۵. نمونه‌برداری، هدایت شرطی، و کنترل در مدل‌های انتشار (۲۰ نمره)

پیش‌زمینه: پرسش پیشین نشان داد که مدل‌های انتشار با پیش‌بینی نویز، تابع امتیاز $\nabla \log p_t(x)$ را یاد می‌گیرند. اما چگونه از این تابع امتیاز برای **نمونه‌برداری** استفاده کنیم؟ همچنین، چگونه می‌توان اطلاعات شرطی (مثل کلاس تصویر) را در تولید داده کنترل کرد؟ این پرسش سه موضوع را بررسی می‌کند: (۱) نمونه‌برداری Langevin، (۲) هدایت با دسته‌بند (Classifier Guidance)، و (۳) هدایت بدون دسته‌بند (Classifier-Free Guidance).

الف) نمونه‌برداری Langevin و میانگین متحرک نویز

(آ) برای نمونه‌برداری از یک توزیع $p(x)$ با استفاده از تابع امتیاز $\nabla \log p(x)$، از Stochastic Gradient Langevin Dynamics (SGLD) استفاده می‌کنیم:

$$x_{k+1} = x_k + \eta \nabla \log p(x_k) + \sqrt{2\eta}\, z_k, \qquad z_k \sim (0, I).$$

نشان دهید که در حد $\eta \to 0$ و با تعداد گام کافی، توزیع x_k به $p(x)$ همگرا می‌شود. (راهنمایی: این یک فرآیند مارکوف با تابع پتانسیل $-\log p(x)$ است که با معادله‌ی فوکر–پلانک توصیف می‌شود.)

(ب) در عمل، تابع امتیاز در نواحی با چگالی کم دقت کافی ندارد — چون در این نواحی داده‌ی کمی برای یادگیری وجود دارد. راه‌حل: **افزودن نویز گاوسی** در چندین مقیاس. فرض کنید نویز $\epsilon \sim (0, \sigma^2 I)$ اضافه می‌کنیم و تابع امتیاز را روی داده‌ی نویزی تخمین می‌زنیم: $x_\sigma = x_0 + \sigma\epsilon$. نشان دهید:

$$\nabla_{x_\sigma} \log p_\sigma(x_\sigma) \approx -\frac{\epsilon_\theta(x_\sigma)}{\sigma},$$

که ϵ_θ شبکه‌ی پیش‌بینی نویز است. چرا با افزایش σ، ناحیه‌ی بیشتری از فضا پوشش داده می‌شود؟

(ج) در **Langevin با میانگین متحرک** (Annealed Langevin Dynamics)، ابتدا با نویز زیاد شروع می‌کنیم و به تدریج نویز را کم می‌کنیم. توضیح دهید چرا این روش بهتر از Langevin با نویز ثابت کار می‌کند. چرا باید **از نویز زیاد به نویز کم** حرکت کنیم (و نه برعکس)؟

ب) هدایت با دسته‌بند: کنترل از طریق گرادیان

(آ) فرض کنید یک دسته‌بند $p(c \mid x)$ آموزش‌دیده داریم. با استفاده از قاعده‌ی بیز، نشان دهید تابع امتیاز شرطی برابر است با:

$$\nabla_x \log p(x \mid c) = \nabla_x \log p(x) + \nabla_x \log p(c \mid x).$$

این نتیجه را با تصویر ساده توضیح دهید: اگر $\nabla_x \log p(x)$ جهت «بهبود کیفیت تصویر» باشد و $\nabla_x \log p(c \mid x)$ جهت «شبیه‌تر شدن به کلاس c»، ترکیب آن‌ها چه جهتی می‌دهد؟

(ب) در هدایت با دسته‌بند (Classifier Guidance)، نمونه‌برداری با اضافه کردن گرادیان دسته‌بند به تابع امتیاز انجام می‌شود:

$$\hat{\nabla} \log p(x_t \mid c) = \nabla \log p(x_t) + w \cdot \nabla_{x_t} \log p(c \mid x_t),$$

که w مقیاس هدایت است. وقتی w افزایش می‌یابد، چه اتفاقی برای کیفیت و تنوع نمونه‌ها می‌افتد؟ بررسی کنید: $w \to \infty$ چه پیامدی دارد؟

(ج) مشکل اصلی هدایت با دسته‌بند چیست؟ (راهنمایی: دسته‌بند روی تصاویر **تمیز** آموزش دیده، ولی در طول نمونه‌برداری، تصاویر **نویزی** هستند.) چرا این ناسازگاری می‌تواند باعث **نمونه‌های خصمانه** (adversarial) شود؟

ج) هدایت بدون دسته‌بند: هوشمندی در سادگی

(آ) برای حذف نیاز به دسته‌بند جداگانه، از Classifier-Free Guidance (CFG) استفاده می‌کنیم. فرض کنید یک مدل انتشار شرطی $\epsilon_\theta(x_t, t, c)$ آموزش می‌دهیم که $10-20\%$ مواقع شرط c را حذف می‌کند (جایگزین با یک توکن خالی $\emptyset$). نشان دهید که با استفاده از ترکیب خطی:

$$\hat{\epsilon}(x_t, t, c) = \epsilon_\theta(x_t, t, \emptyset) + w \cdot \big(\epsilon_\theta(x_t, t, c) - \epsilon_\theta(x_t, t, \emptyset)\big),$$

در فضای تابع امتیاز معادل حرکت در جهت $\nabla_{x_t} \log p(c \mid x_t)$ هستیم. (راهنمایی: از رابطه‌ی بیز استفاده کنید و $\nabla \log p(x_t \mid c) - \nabla \log p(x_t)$ را محاسبه کنید.)

(ب) نشان دهید وقتی $w \to \infty$، نمونه‌برداری $\hat{\epsilon}$ به $_{x_t}p(c \mid x_t)$ میل می‌کند (نه نمونه‌برداری تصادفی از توزیع شرطی). این یعنی CFG با w بزرگ دچار **پختگی بیش از حد** (overcooked) می‌شود: تصاویر شبیه کلاس هستند ولی تنوع کم است. سپس بحث کنید:

(آ) چرا CFG یک «هک» هوشمندانه است؟ (پاسخ: چون مدل مولد را مجبور می‌کنیم هم شرطی و هم غیرشرطی یاد بگیرد.)

(ب) چرا CFG در عمل بهتر از هدایت با دسته‌بند کار می‌کند؟ (دو دلیل: نیاز به دسته‌بند جداگانه ندارد، و گرادیان‌های خصمانه تولید نمی‌کند.)

د) مقایسه‌ی روش‌های هدایت و طراحی سیستم

(آ) جدول زیر را تکمیل کنید و ذیل جدول برای هر ویژگی یک جمله توضیح دهید:

ویژگی	Classifier Guidance	Classifier-Free Guidance
نیاز به دسته‌بند جداگانه؟	.....	.....
دسته‌بند باید روی تصاویر نویزی آموزش ببیند؟	.....	.....
تعداد مدل‌های مورد نیاز	.....	.....
خطر گرادیان خصمانه؟	.....	.....

(ب) فرض کنید می‌خواهید یک سیستم تولید تصویر با کنترل شرطی بسازید:

(آ) اگر کیفیت بالا با قیمت تنوع کم مطلوب باشد (مثل تولید تصویر دقیق از یک کلاس)، w را چقدر انتخاب می‌کنید و چرا؟

(ب) اگر تنوع بالا با کیفیت متوسط مطلوب باشد (مثل تولید تصاویر متنوع برای augmentation)، w را چقدر انتخاب می‌کنید و چرا؟

(ج) اگر هم کیفیت و هم تنوع مهم باشد، چه راهکاری پیشنهاد می‌دهید؟ (راهنمایی: به ترکیب نمونه‌برداری DDPM و DDIM فکر کنید.)

پاسخ. ▷

الف)

(آ) **همگرایی Dynamics: Langevin** SGLD یک فرآیند مارکوف با تابع پتانسیل $U(x) = -\log p(x)$ است. معادله‌ی آن را می‌توان به صورت زیر نوشت:

$$dx = -\nabla U(x)dt + \sqrt{2}dW_t = \nabla \log p(x)dt + \sqrt{2}dW_t.$$

چگالی $p_t(x)$ این فرآیند در معادله‌ی فوکر–پلانک صدق می‌کند:

$$\partial_t p_t = \nabla \cdot (p_t \nabla U) + \Delta p_t = \nabla \cdot \Big(p_t \nabla \log \frac{p_t}{p} \Big).$$

این معادله نشان می‌دهد که p_t به سمت p (توزیع پایدار) همگرا می‌شود، زیرا $\frac{d}{dt} D_{\mathrm{KL}}(p_t \| p) = -_{p_t}[\|\nabla \log \frac{p_t}{p}\|^2] \leq 0$. در حد $\eta \to 0$ و تعداد گام زیاد، نمونه‌های SGLD از $p(x)$ نمونه‌برداری می‌کنند.

(ب) **تابع امتیاز داده‌ی نویزی:** برای $x_\sigma = x_0 + \sigma\epsilon$، چگالی شرطی $p(x_\sigma \mid x_0) = (x_0, \sigma^2 I)$. بنابراین:

$$\nabla_{x_\sigma} \log p(x_\sigma \mid x_0) = -\frac{x_\sigma - x_0}{\sigma^2} = -\frac{\epsilon}{\sigma}.$$

از طرف دیگر، چگالی حاشیه‌ای $p_\sigma(x_\sigma) = \int p(x_0) p(x_\sigma \mid x_0) dx_0$ و شبکه‌ی پیش‌بینی نویز $\epsilon_\theta(x_\sigma) \approx \epsilon$ تخمین می‌زند. بنابراین:

$$\nabla_{x_\sigma} \log p_\sigma(x_\sigma) \approx -\frac{\epsilon_\theta(x_\sigma)}{\sigma}.$$

با افزایش σ، نویز بیشتری اضافه می‌شود و توزیع p_σ پهن‌تر می‌شود. این باعث می‌شود تابع امتیاز در نواحی دوردست‌تر از داده‌ها نیز معتبر باشد و پوشش فضا بهتر شود.

(ج) **Dynamics: Langevin Annealed** این روش بهتر کار می‌کند زیرا:

- در مراحل اولیه با نویز زیاد (σ بزرگ)، فضای وسیعی اکتشاف می‌شود و از گیر افتادن در مدهای محلی جلوگیری می‌شود.
- در مراحل نهایی با نویز کم (σ کوچک)، روی جزئیات دقیق داده تمرکز می‌کنیم و کیفیت نمونه‌ها افزایش می‌یابد.
- حرکت از نویز کم به زیاد کارایی ندارد زیرا در نویز کم ممکن است در مدهای محلی گیر بیفتیم و سپس افزایش نویز کیفیت را خراب کند.

ب)

(آ) **تابع امتیاز شرطی از قاعده‌ی بیز:** با استفاده از $p(x \mid c) = \frac{p(c|x)p(x)}{p(c)}$ و لگاریتم‌گیری:

$$\log p(x \mid c) = \log p(c \mid x) + \log p(x) - \log p(c).$$

چون $p(c)$ مستقل از x است، گرادیان نسبت به x:

$$\nabla_x \log p(x \mid c) = \nabla_x \log p(x) + \nabla_x \log p(c \mid x).$$

تفسیر هندسی: $\nabla_x \log p(x)$ جهت «بهبود کیفیت کلی تصویر» (حرکت به سمت داده‌های واقعی) و $\nabla_x \log p(c \mid x)$ جهت «شبیه‌تر شدن به کلاس c» است. ترکیب آن‌ها جهتی می‌دهد که هم کیفیت خوب داشته باشد و هم شرط c را برآورده کند.

(ب) **اثر مقیاس هدایت w:** با افزایش w، جمله‌ی $\nabla_x \log p(c \mid x)$ سنگینی بیشتری می‌کند. وقتی $w \to \infty$:

$$\hat{\nabla} \log p(x \mid c) \approx w \nabla_x \log p(c \mid x).$$

این یعنی نمونه‌ها به سمت نقاطی حرکت می‌کنند که دسته‌بند با اطمینان بالا کلاس c را پیش‌بینی می‌کند. این باعث **افزایش کیفیت individual** ولی **کاهش تنوع** می‌شود — چون نمونه‌ها به نواحی با confidence بالا محدود می‌شوند.

(ج) **مشکل هدایت با دسته‌بند:** دسته‌بند $p(c \mid x)$ روی تصاویر **تمیز** آموزش دیده است. اما در طول نمونه‌برداری، ورودی دسته‌بند تصاویر **نویزی** x_t هستند. این ناسازگاری باعث می‌شود:

- دسته‌بند در نواحی نویزی confidence پایین داشته باشد.
- گرادیان $\nabla_{x_t} \log p(c \mid x_t)$ می‌تواند در جهت‌های خصمانه (adversarial) اشاره کند — یعنی نمونه را تغییر دهد تا دسته‌بند گمراه شود، نه اینکه واقعاً شبیه کلاس c شود.
- نیاز به آموزش مجدد دسته‌بند روی تصاویر نویزی داریم که پیچیدگی را افزایش می‌دهد.

ج)

(آ) **تشابه CFG با هدایت بیزی:** از قاعده‌ی بیز در فضای نویز داریم:

$$\nabla_{x_t} \log p(x_t \mid c) = \nabla_{x_t} \log p(x_t) + \nabla_{x_t} \log p(c \mid x_t).$$

با استفاده از رابطه‌ی بین تابع امتیاز و پیش‌بینی نویز، $\nabla_{x_t} \log p(x_t) \approx -\frac{\epsilon_\emptyset}{\sqrt{1-\bar{\alpha}_t}}$ و $\nabla_{x_t} \log p(x_t \mid c) \approx -\frac{\epsilon_c}{\sqrt{1-\bar{\alpha}_t}}$. بنابراین:

$$\nabla_{x_t} \log p(c \mid x_t) \approx -\frac{\epsilon_c - \epsilon_\emptyset}{\sqrt{1-\bar{\alpha}_t}}.$$

حال اگر در فرمول هدایت با دسته‌بند، $\nabla_{x_t} \log p(x_t)$ را با $\epsilon_\emptyset$ و $\nabla_{x_t} \log p(x_t \mid c)$ را با ϵ_c جایگزین کنیم، به فرمول CFG می‌رسیم:

$$\hat{\epsilon} = \epsilon_\emptyset + w(\epsilon_c - \epsilon_\emptyset).$$

این یعنی CFG یک **درون‌یابی-برون‌یابی** (extrapolation) در فضای نویز است که جهت تابع امتیاز شرطی را تقریب می‌زند.

(ب) **رفتار در حد $w \to \infty$ و برتری CFG:**

(آ) **هوشمندی CFG:** CFG با یک تغییر ساده در آموزش dropout) شرط با احتمال ۱۰-۲۰٪) و یک خط کد در نمونه‌برداری، هدایت را بدون هیچ هزینه‌ی اضافی پیاده‌سازی می‌کند. این سادگی و کارایی آن را به یک «هک» هوشمندانه تبدیل کرده است.

(ب) **برتری نسبت به Guidance: Classifier**

- **بدون دسته‌بند جداگانه:** نیازی به آموزش، نگهداری، و اجرای یک دسته‌بند دوم نیست.
- **بدون ناسازگاری نویز:** مدل انتشار شرطی روی همان توزیع نویزی آموزش دیده که نمونه‌برداری از آن انجام می‌شود. بنابراین خروجی‌های ϵ_c و $\epsilon_\emptyset$ هر دو برای نویز x_t معتبر هستند.
- **بدون گرادیان خصمانه:** چون از تفاضل دو خروجی مدل مولد استفاده می‌کنیم (نه گرادیان یک دسته‌بند)، جهت حرکت طبیعی و غیرخصمانه است.

د)

(آ) **جدول تکمیل‌شده:**

ویژگی	Guidance Classifier	Guidance Classifier-Free
نیاز به دسته‌بند جداگانه؟	بله	خیر
دسته‌بند باید روی تصاویر نویزی آموزش ببیند؟	بله	خیر
تعداد مدل‌های مورد نیاز	۲ (انتشار + دسته‌بند)	۱ (انتشار شرطی با dropout)
خطر گرادیان خصمانه؟	بله	خیر

توضیحات:

- **نیاز به دسته‌بند جداگانه:** Guidance Classifier نیاز به دسته‌بند جداگانه دارد زیرا $\nabla_{x_t} \log p(c|x_t)$ باید از یک مدل دسته‌بند محاسبه شود. CFG فقط یک مدل انتشار دارد.
- **آموزش روی تصاویر نویزی:** Guidance Classifier نیاز به آموزش دسته‌بند روی x_tهای نویزی دارد، در حالی که CFG از dropout در مدل انتشار استفاده می‌کند.
- **تعداد مدل:** CG به ۲ مدل نیاز دارد (انتشار غیرشرطی + دسته‌بند). CFG یک مدل دارد که هم شرطی و هم غیرشرطی عمل می‌کند.
- **خطر خصمانه:** CG از گرادیان دسته‌بند (آموزش‌دیده روی clean) روی نویز استفاده می‌کند = ad- versarial. CFG از تفاضل دو خروجی مدل مولد استفاده می‌کند = غیرخصمانه.

(ب) **طراحی سیستم:**

(آ) **کیفیت بالا با قیمت تنوع کم:** w بزرگ (مثلاً $w = 5$ تا 10). این باعث می‌شود نمونه‌ها بسیار شبیه کلاس c شوند ولی تنوع کمتری داشته باشند. برای تولید تصویر دقیق از یک کلاس خاص مناسب است.

(ب) **تنوع بالا با کیفیت متوسط:** w کوچک (مثلاً $w = 1$ تا 2) یا حتی $w = 0$ (نمونه‌برداری غیرشرطی). این حالت تنوع بیشتری دارد و برای augmentation که هدف آن پوشش فضای وسیع‌تری از داده است، مناسب‌تر است.

(ج) **تعادل کیفیت و تنوع:** w متوسط (مثلاً $w = 3$ تا 5) و استفاده از DDPM با گام‌های کافی (مثلاً ۵۰-۱۰۰). همچنین می‌توان از تکنیکی به نام negative prompting یا نمونه‌برداری چندگانه با wهای مختلف و انتخاب بهترین نمونه‌ها استفاده کرد. ترکیب DDPM (برای تنوع) با تعداد گام متوسط (برای سرعت) و w متوسط (برای کیفیت) تعادل خوبی ایجاد می‌کند.